

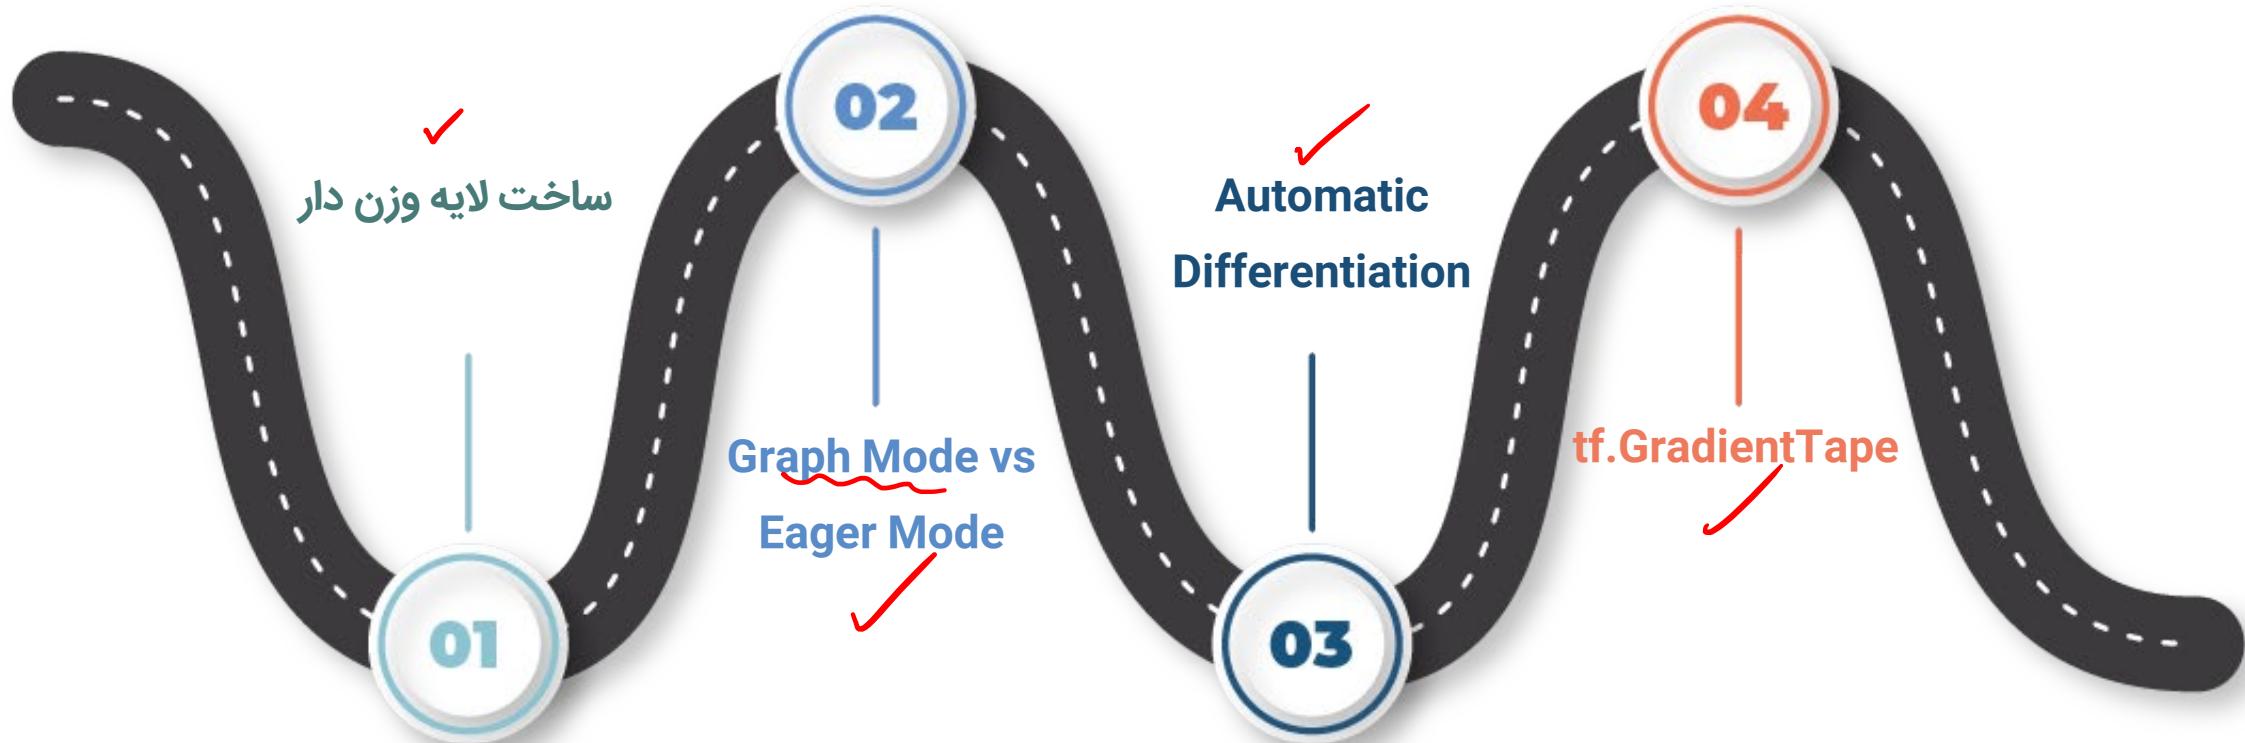
دوره تنسورفلو پیشرفته

{ eager
graph }

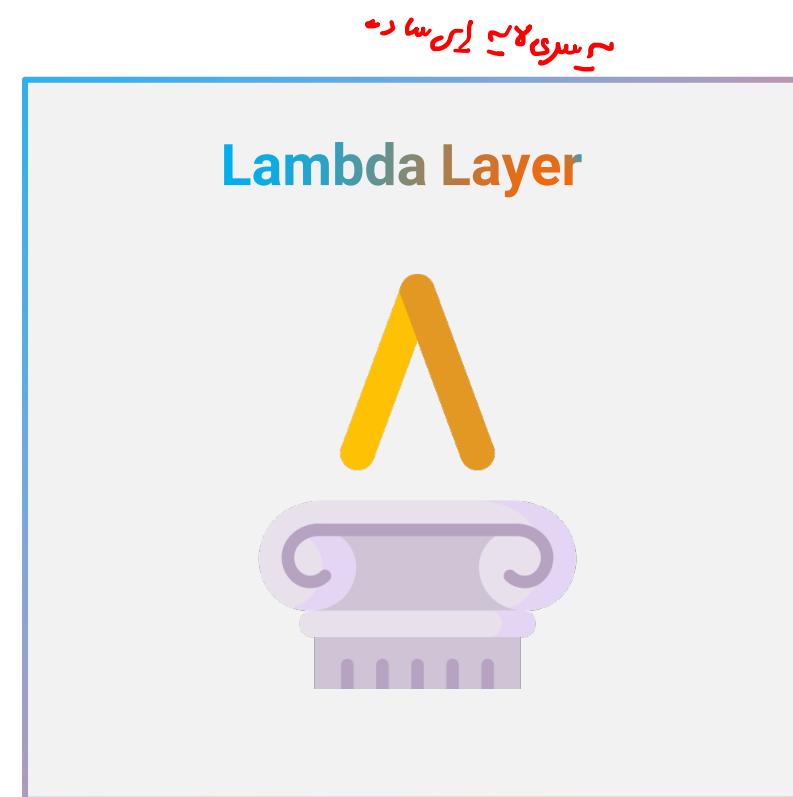
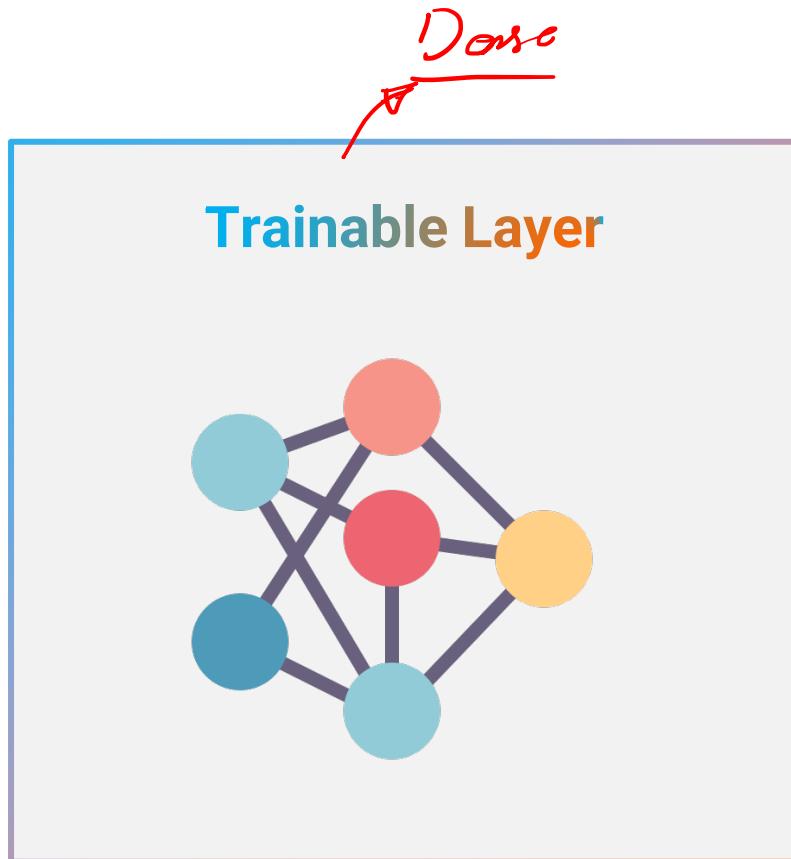
جلسه پنجم : ساخت لایه وزن دار و مدهای اجرایی Tensorflow



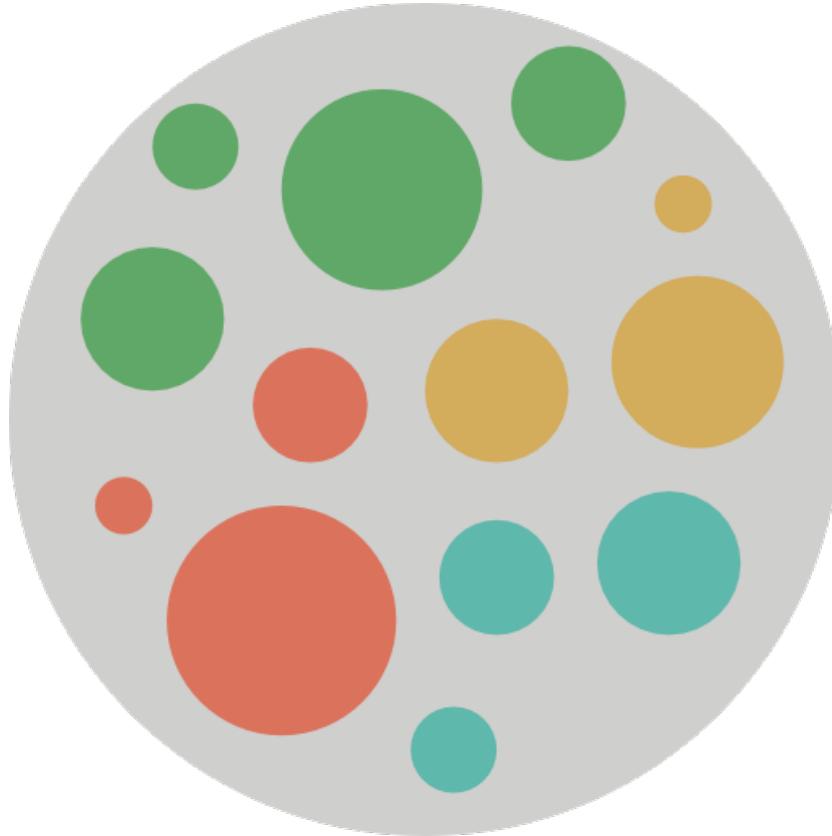
آنچه امروز خواهیم گفت :



انواع روش های نوشتن لایه در Tensorflow



Dense : ساخت لایه

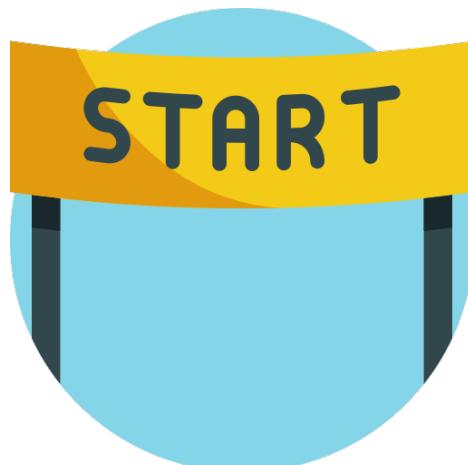


init متد

-init → متد ایجاد کننده
build → ذخیره کردن
cell_size → اندازه کوکا

Dove - گذاشتن

```
def __init__(self, units = 32):  
    super().__init__()  
    self.units = units
```



tf.random_normal_initializer

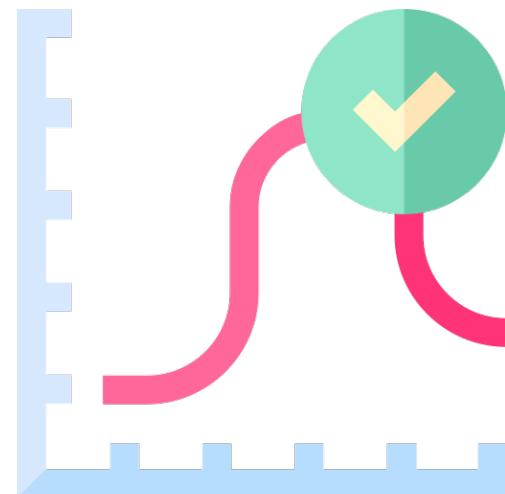
w_init ↗

{ callable
object } ↗
obj ↗

```
tf.random_normal_initializer(  
    mean=0.0, stddev=0.05, seed=None)
```

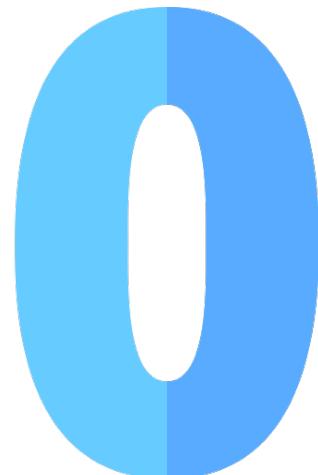
w-init = ...

w-init(
 c
) ↗



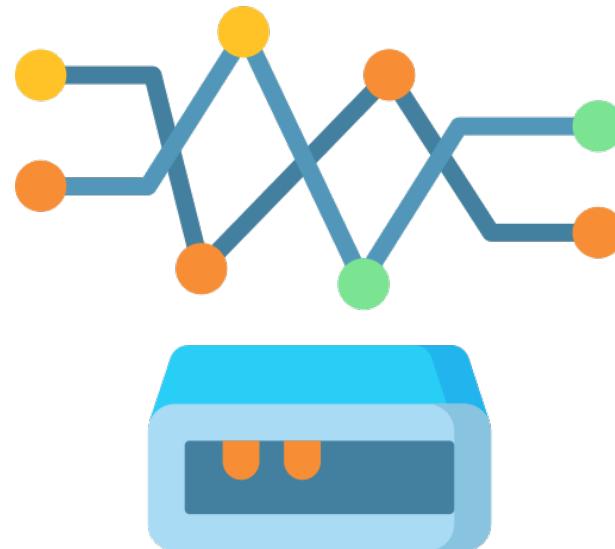
tf.zeros_initializer

✓ tf.zeros_initializer()



tf.Variable

```
tf.Variable(initial_value= ... ,  
           trainable=...), trainable=  
           name = ... )
```



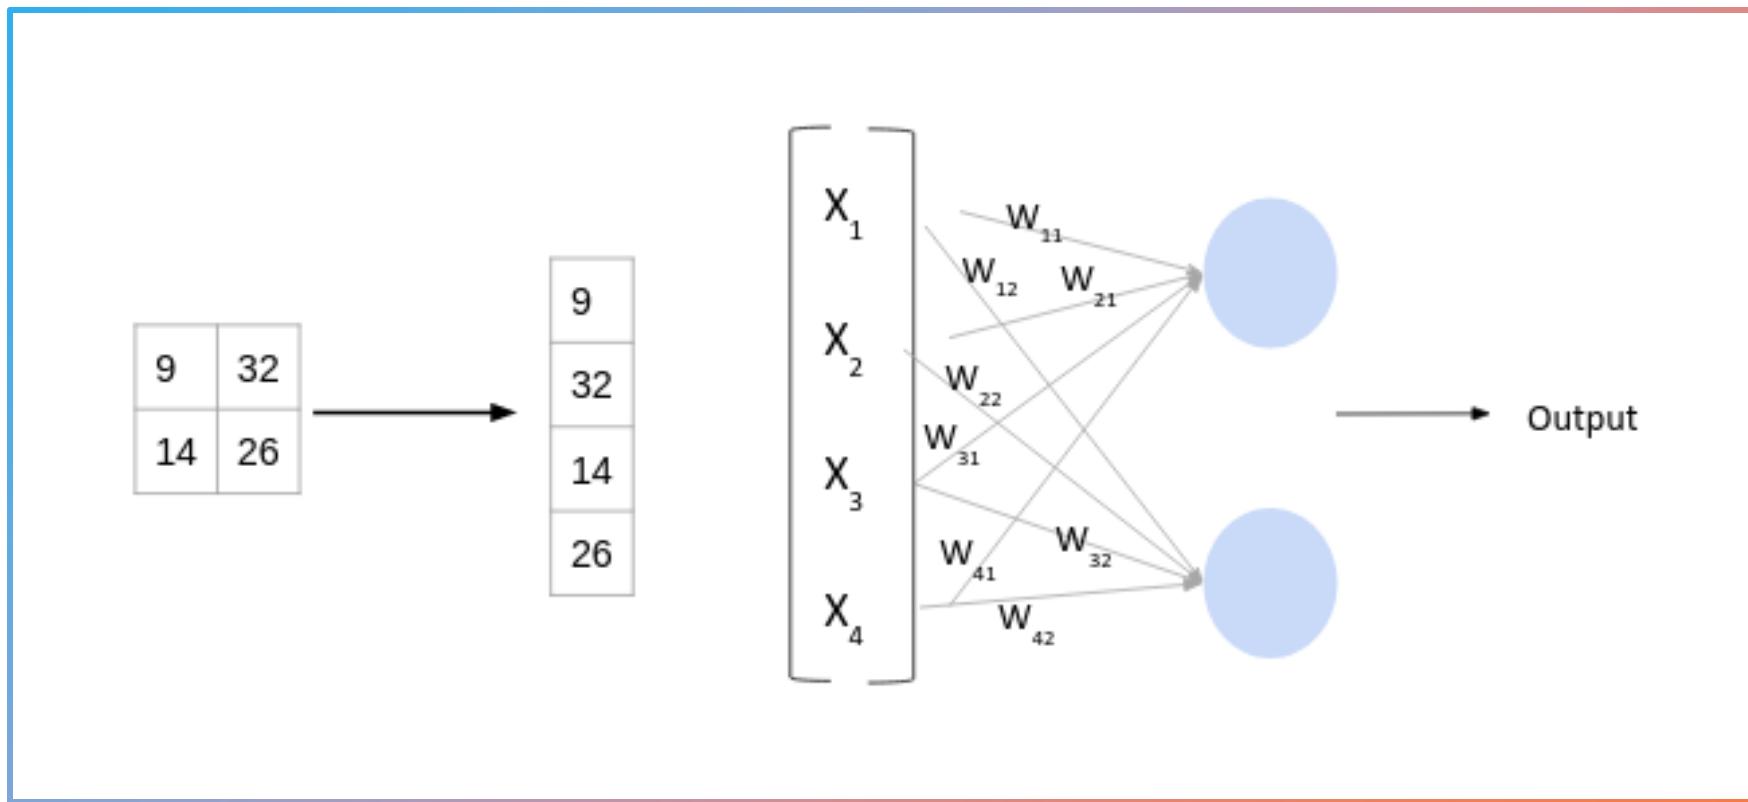
[]

tf.Variable مثال

```
self.w = tf.Variable(initial_value=w_init(shape = (input_shape[-1], self.units),  
                                         dtype = "float32"), trainable = True, name="kernel")
```



مرواری بر ابعاد در لایه Dense



ابعاد ورودی و خروجی و وزن و بایاس به چه شکل است ؟

ابعاد محاسبات در Dense

$$y = \underbrace{x_{(1 \times n)}}_{n : \text{Input dim}} \underbrace{W_{(n \times m)}}_{\text{self.units}} + \underbrace{b_{(1 \times m)}}_{m: \text{units}}$$

input_shape[-1]



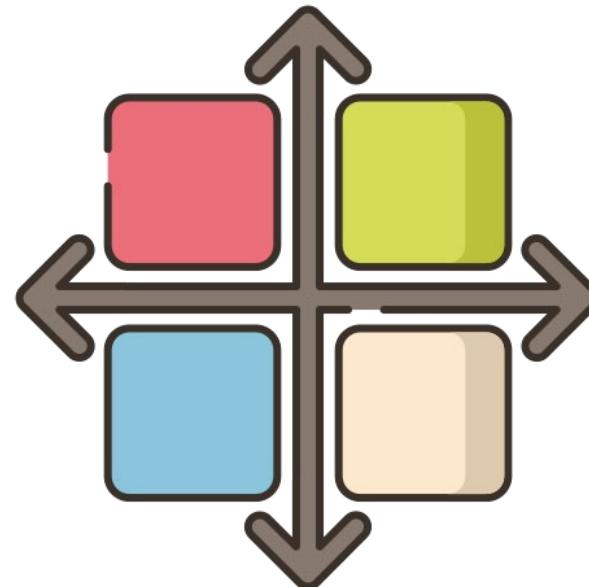
build متد

```
def build(self, input_shape):
    w_init = tf.random_normal_initializer()
    self.w = tf.Variable(initial_value=w_init(shape = (input_shape[-1], self.units),
                                              dtype = "float32") ,trainable = True, name = "kernel")

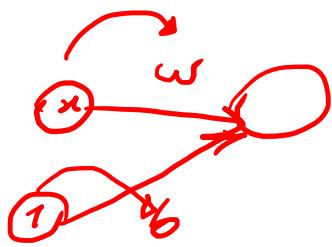
    b_init = tf.zeros_initializer()
    self.b = tf.Variable(initial_value=w_init(shape=(self.units,)),
                         dtype="float32"), trainable =True, name="bias")
```

call متده

```
def call(self, inputs):  
    return tf.matmul(inputs, self.w) + self.b
```



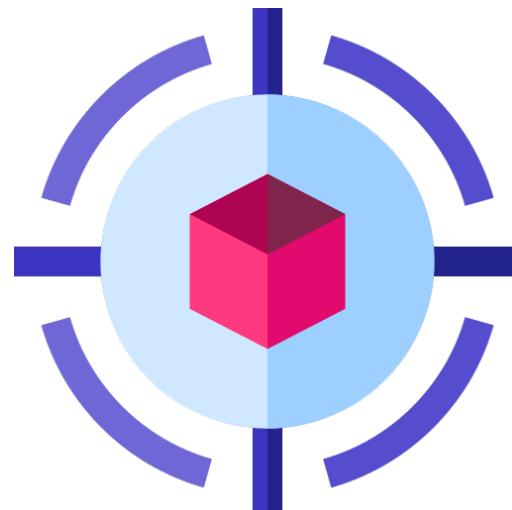
یک بررسی کوچک برای درک بهتر



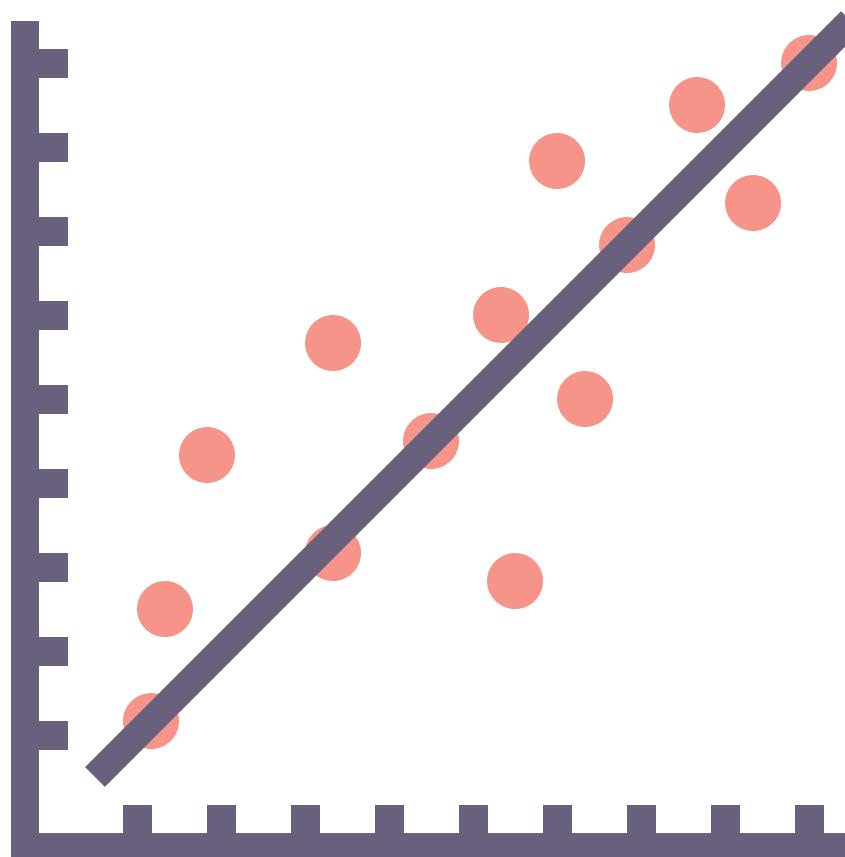
$$y = \begin{matrix} x \\ 1 \end{matrix} \begin{matrix} w \\ b \end{matrix}$$

```
my_dense = SimpleDense(units=1)
x = tf.ones((1,1))
y = my_dense(x)
print(my_dense.variables)
```

$$y = x_{(1 \times n)} W_{(n \times m)} + b_{(1 \times m)}$$



حل یک مثال:



یک مثال ساده:

$$y = 2x - 1$$

$$\begin{cases} \omega \approx 1 \\ b \approx -1 \end{cases}$$

```
xs = np.array([-1.0, 0.0, 1.0, 2.0, 3.0, 4.0], dtype = float)
ys = np.array([-3.0, -1.0, 1.0, 3.0, 5.0, 7.0], dtype=float)

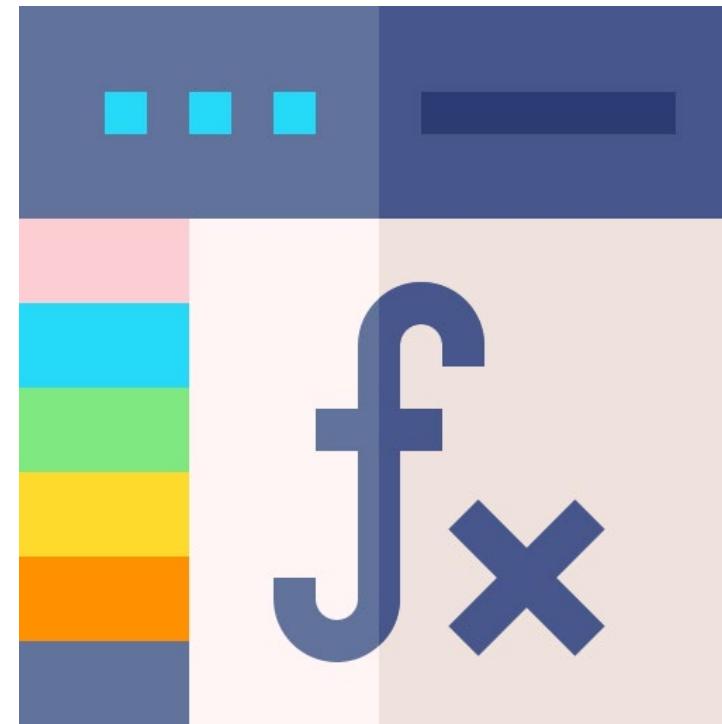
model = tf.keras.Sequential([
    SimpleDense(1)
])

model.compile(optimizer="sgd", loss = "mean_squared_error")
model.fit(xs, ys, epochs = 500)
print(model.predict([10.0]))
```

$2x - 1 \rightarrow 2 \times 10 - 1 \approx 19$

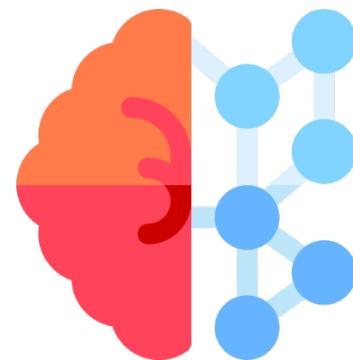
و البتہ ضرایب را ہم بیینیں:

```
print(model.variables)
```



یک مثال کاملتر:

```
net = models.Sequential([  
    layers.Flatten(input_shape= (28 ,28)),  
    SimpleDense(units = 128),  
    layers.Lambda(lambda x:tf.maximum(x, 0.0)),  
    SimpleDense(units=10),  
    layers.Activation("softmax")  
])
```



softmax و حتى

$$\frac{e^{P_i}}{\sum e^{P_i}}$$

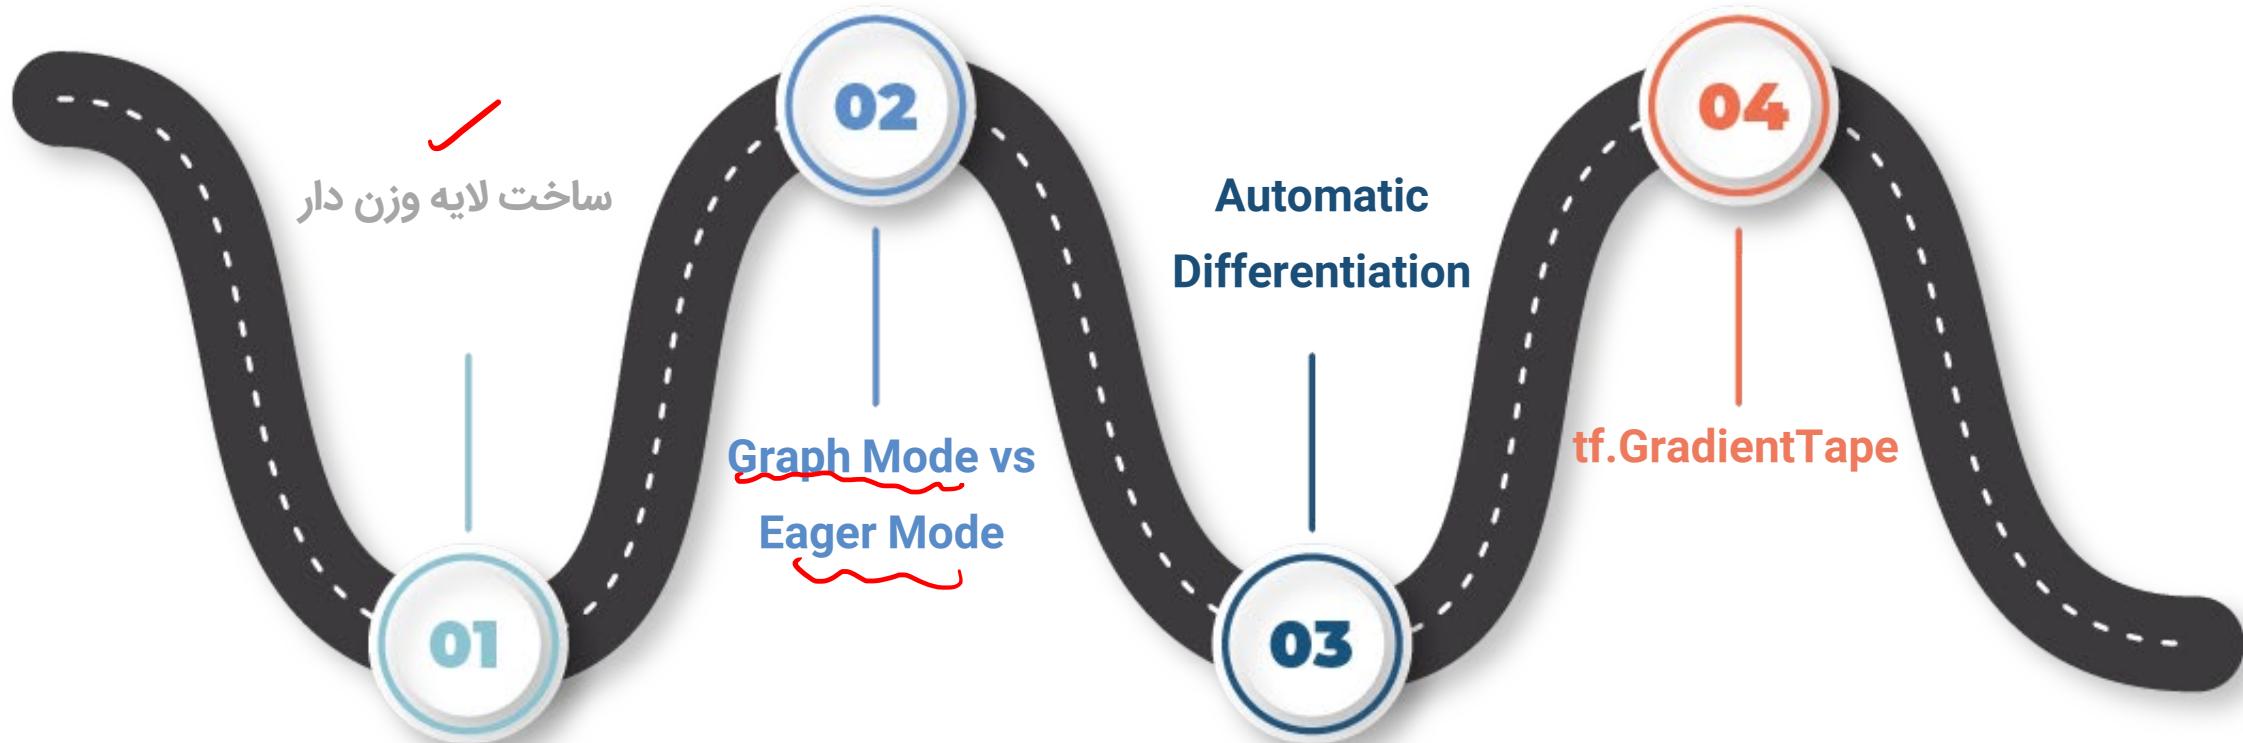
$$[a, b, c]$$

$$\frac{e^a}{e^a + e^b + e^c}$$

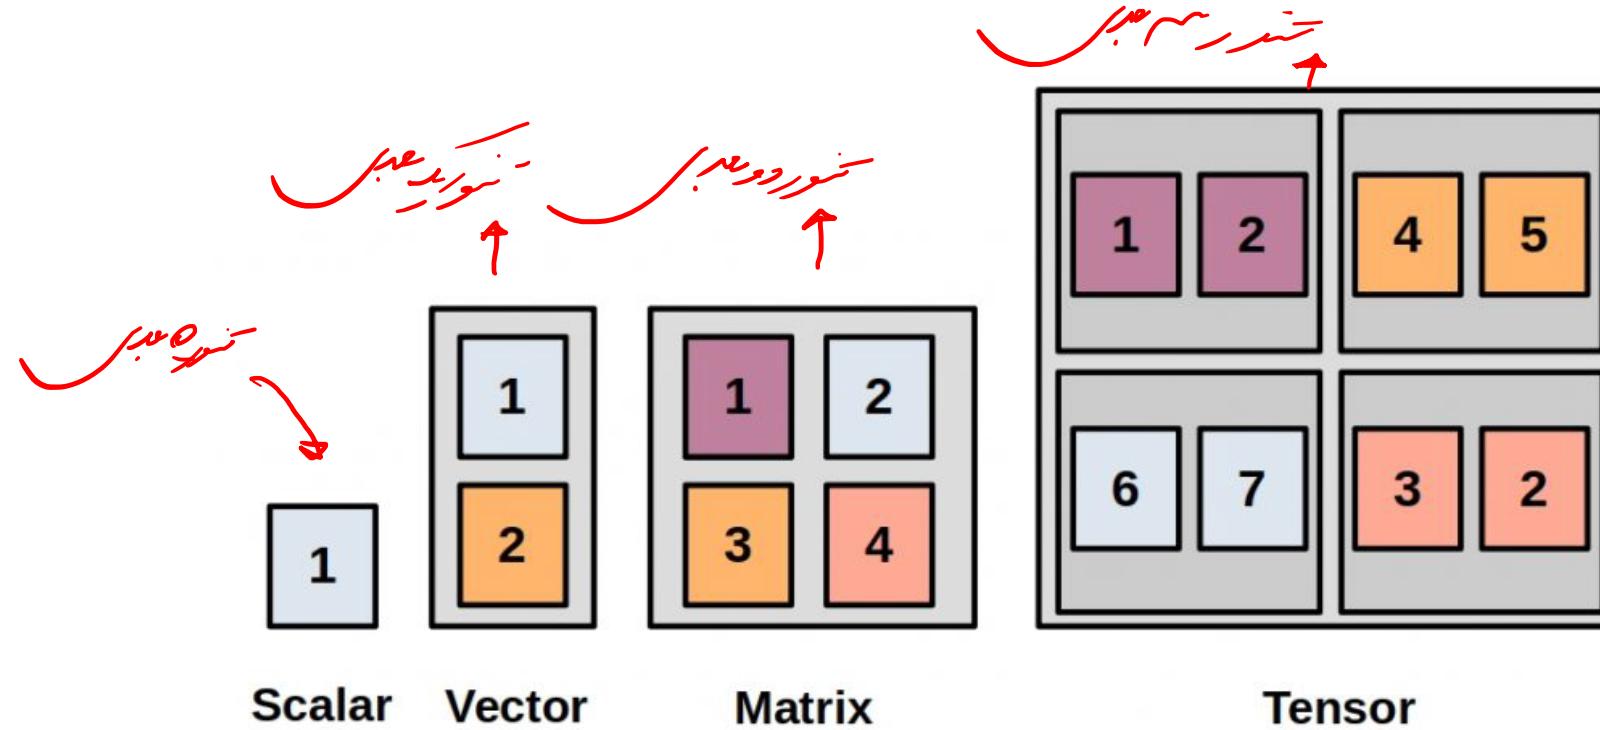
```
def softmax(x):  
    e_x = tf.exp(x)  
    return e_x / tf.reduce_sum(e_x)
```



آنچه امروز خواهیم گفت :

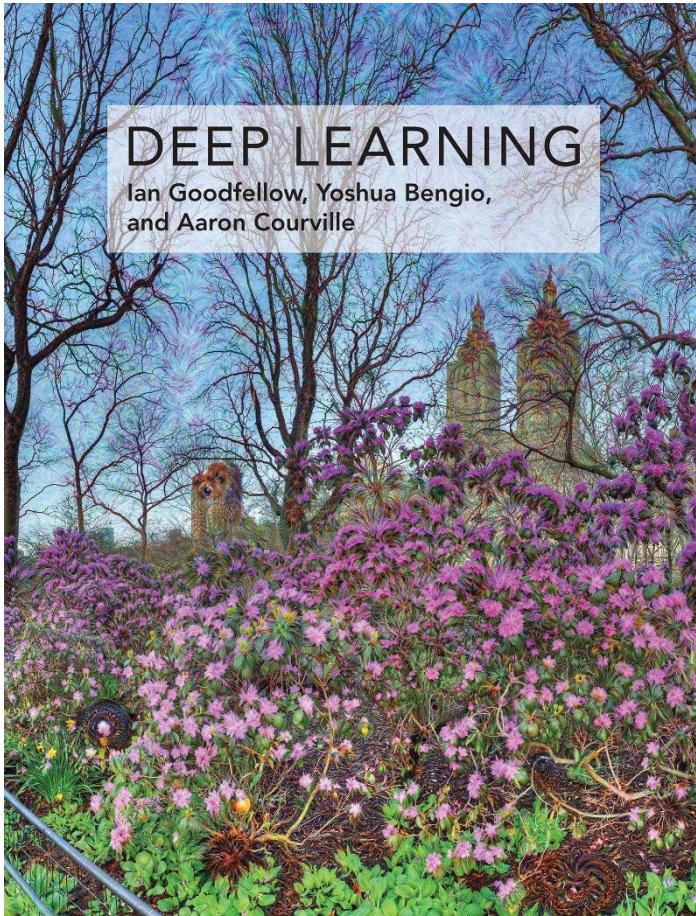


تنسور چیست؟



تنسور یک داده ساختار انعطاف پذیر است که می تواند داده ها را در تعداد ابعاد متنوعی در خود نگه دارد.

تنسور از نگاه بزرگان



In the general case, an array of numbers arranged on a regular grid with a variable number of axes is known as a tensor.

دو روش ایجاد تنسور در تنسورفلو

Variables : **tf.Variable**

ten1 = tf.Variable("Hello", dtype = tf.string)



Complex

Constants : **tf.constant**



ten2 = tf.constant([1, 2, 3, 4, 5, 6])



ساختار یک تنسور در تنسورفلو

Tensor

✓ Shape
~~~~~

✓ Data Type  
~~~~~

مثال:

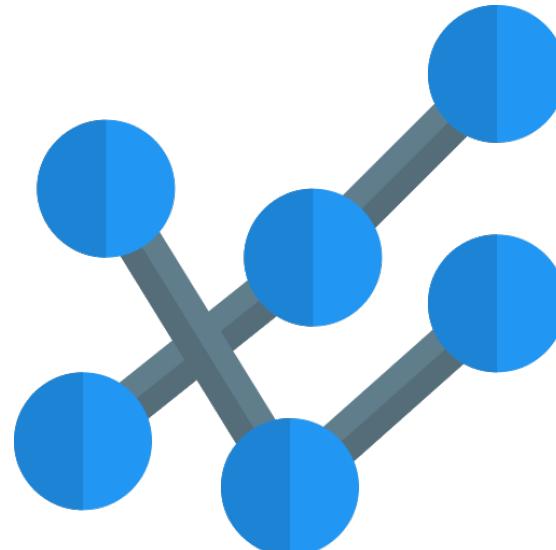
```
model = tf.keras.Sequential([  
    tf.keras.layers.Dense(1, input_shape=(1,))  
])  
  
print(model.variables)
```



```
[ < tf.Variable 'dense/kernel:0' shape = (1, 1) dtype = float32 numpy = array([[1.02298  
34]], dtype=float32) > ,  
  < tf.Variable 'dense/bias:0' shape = (1,) dtype = float32, numpy = array([0.], dtype=f  
loat32) > ]
```

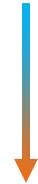
tf.Variable چه Tensor ساخت

```
vector = tf.Variable(initial_value=[1, 2])  
<tf.Variable 'Variable:0' shape=(2,) dtype=int32, numpy=array([1, 2])>
```



یک تذکر در ساخت !Tensor

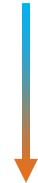
```
vector = tf.Variable([1, 2], tf.float32)
```



```
<tf.Variable 'Variable:0' shape = (2,) dtype = int32, numpy = array([1, 2]) >
```

tf.Variable چه Tensor ساخت

```
vector = tf.Variable([1, 2, 3, 4], dtype=tf.float32)
```



```
<...dtype = float32, numpy = array([1., 2., 3., 4.], dtype=float32) >
```

اشتباه متداول !

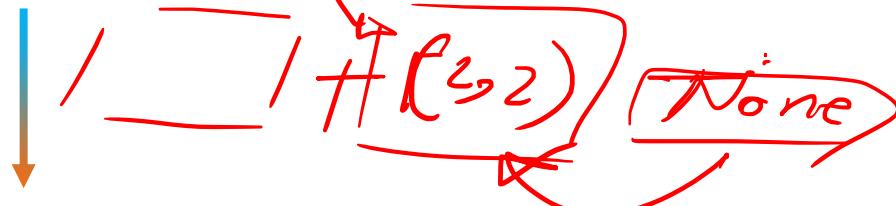
```
vector = tf.Variable([1, 2, 3, 4], shape=(2, 2))
```



```
ValueError: The initial value's shape((4,)) is not compatible with  
the explicitly supplied `shape` argument((2, 2)).
```

راه درست:

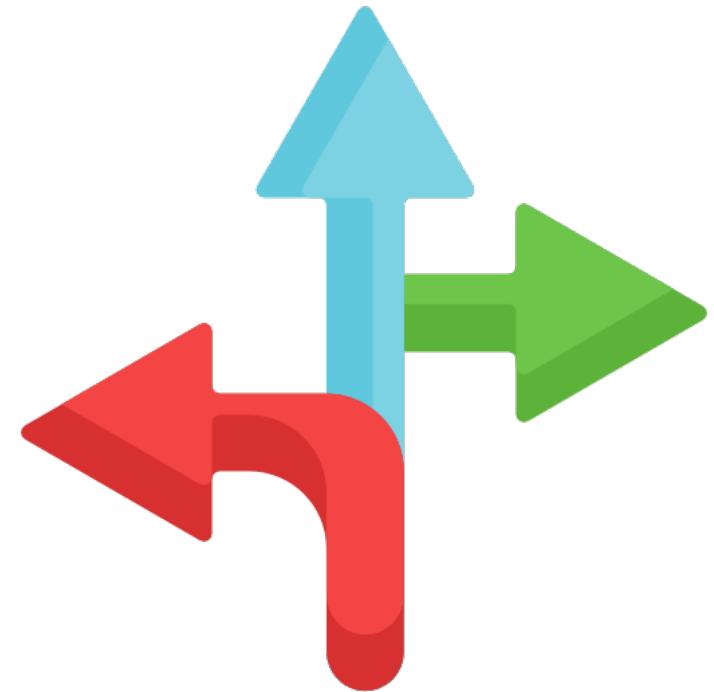
```
vector = tf.Variable([[1, 2],[3, 4]])
```



```
<tf.Variable 'Variable:0' shape = (2, 2) dtype = int32, numpy =
array([[1, 2],
       [3, 4]]) >
```

انعطاف پذیری tf.Variable در ساخت تنسور

```
str_tensor = tf.Variable("Elephant", dtype=tf.string)  
complicated_number = tf.Variable(4+3j, dtype=tf.complex64)  
first_primes = tf.Variable([1, 2, 3, 4])    ✓  
linear_squares = tf.Variable([[1, 2], [3, 4]]) ✓
```



استفاده از Tensor در ساخت tf.constant

```
tensor = tf.constant([1, 2, 3])
```



```
tf.Tensor([1 2 3], shape=(3,), dtype=int32)
```

اینجا از shape می توانیم استفاده کنیم !

```
tensor = tf.constant([1, 2, 3, 4], shape=(2, 2))
```

✓ *shapeTensor.shape(None)*

x + -



```
tf.Tensor(  
    [[1 2]  
     [3 4]], shape=(2, 2), dtype=int32)
```

ساخت Tensor با المان های یکسان!

```
tensor = tf.constant(-1, shape=(2, 3))
```

```
tf.Tensor(  
[[ -1 - 1 - 1]  
[ -1 - 1 - 1]], shape=(2, 3), dtype=int32)
```

عملیات های ریاضی با تنسورها



عملیات های ریاضی بر روی تنسورها

```
tf.subtract([1, 2], [4, 3]) → [4 6]  
add_tensor = tf.add([1, 2], [3, 4]) → [-3 - 1]  
x = tf.constant(([1, 2, 3, 4]))  
tf.math.multiply(x, x) → [ 1, 4, 9, 16]
```

تبدیل نوع داده تنسورها:

```
x = tf.Variable([1, 2, 3, 4])  
x = tf.cast(x, tf.float32)
```

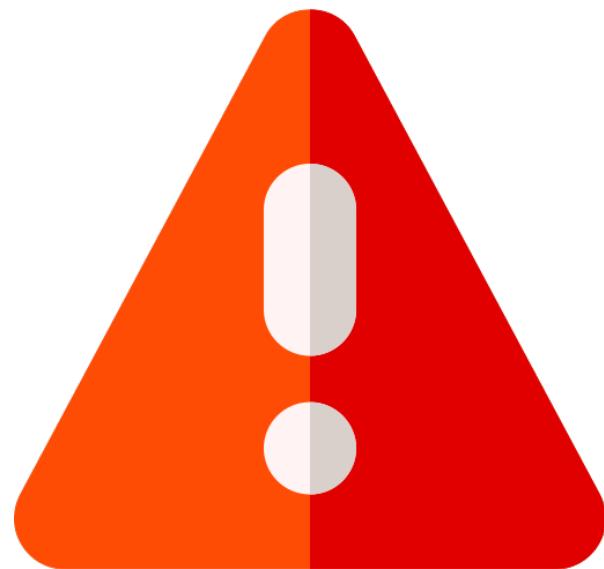
int32

132

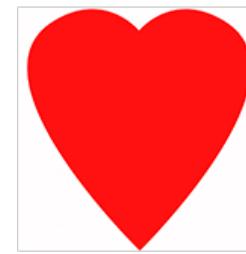
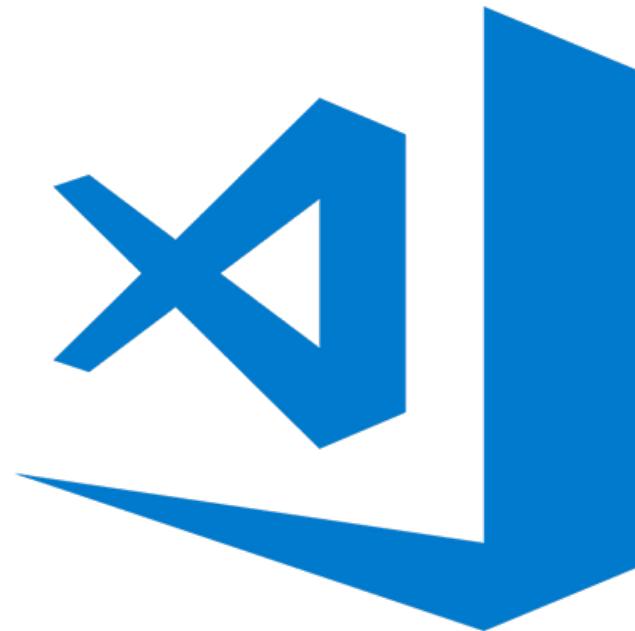
```
tf.Tensor([1. 2. 3. 4.], shape=(4,), dtype=float32)
```

تذکر:

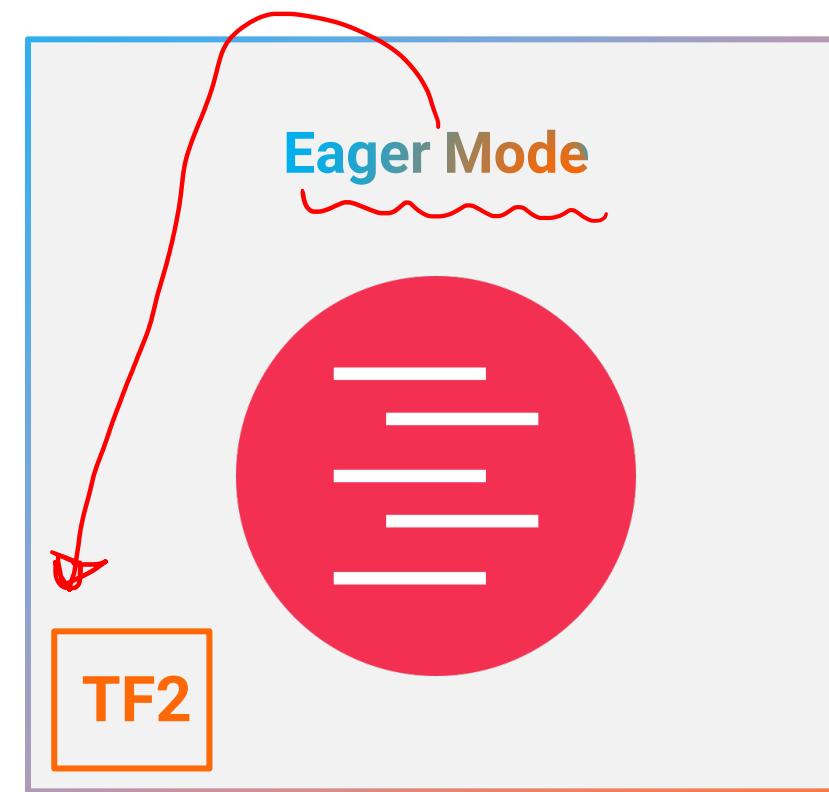
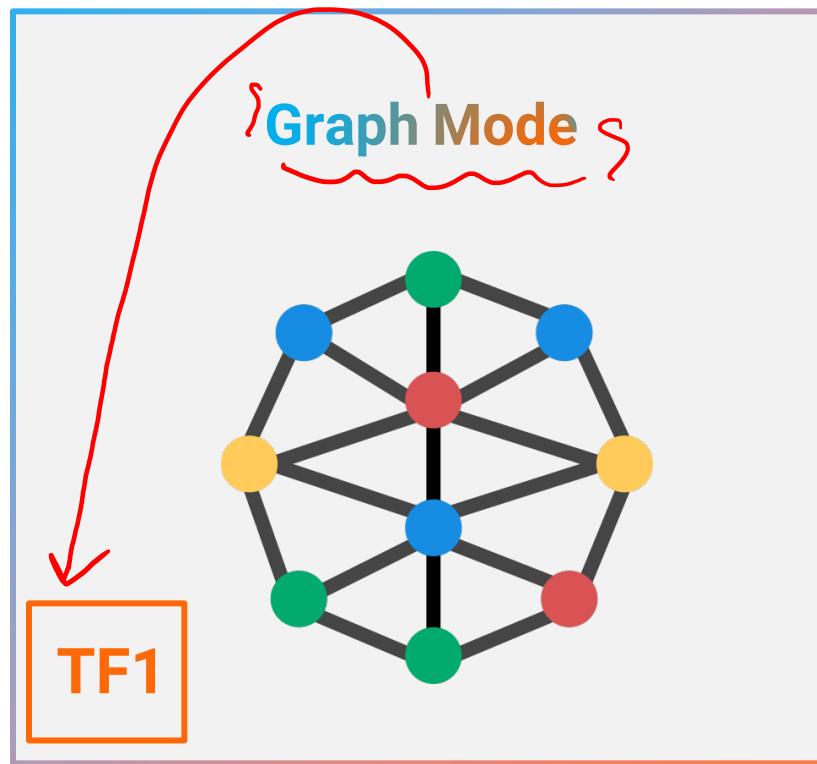
در انجام عملیات های تنسوری به یکی بودن نوع داده ها دقت کنید.



یه دور سریع همین دستورات رو اجرا کنیم !



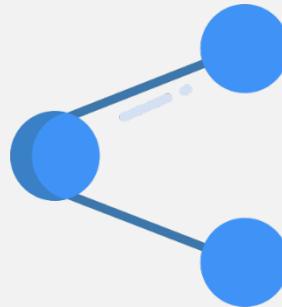
مدهای اجرایی کد در Tensorflow



TF1

چگونه کار می کرد ؟ Graph Mode

یک Computational Graph بساز



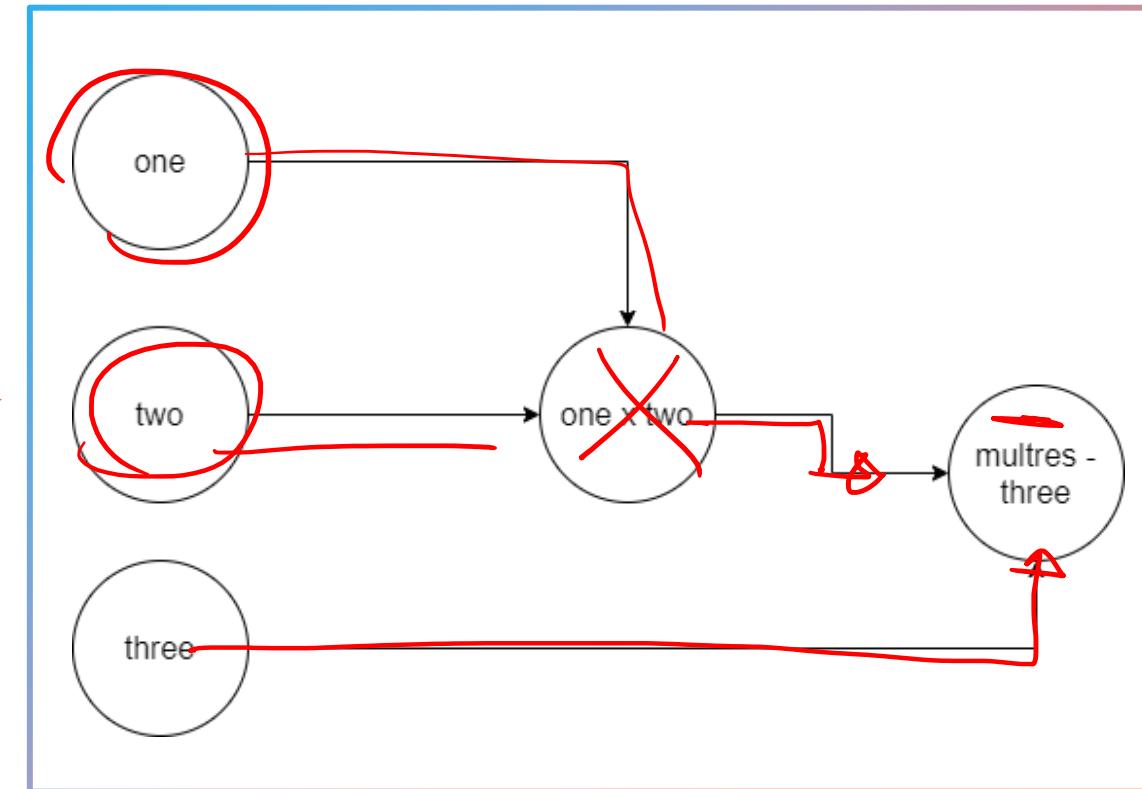
با session اجرا کن !



TF1

یک مثال برای درگ بهتر:

```
one = tf.constant([12])
two = tf.constant([3])
three = tf.constant([2])
multres = tf.math.multiply(one, two)
subres = multres - three
```



TF1

یعنی خروجی این کد به شکل زیر بود:

```
one = tf.constant([12])
two = tf.constant([3])
three = tf.constant([2])
multres = tf.math.multiply(one, two)
subres = multres - three
```

$$12 \times 3 = 36$$

$$36 - 2 = 34$$

```
Tensor("sub: 0", shape=(1,), dtype=int32)
```

عدسی

TF1

برای اجرا باید به صورت زیر عمل می کردیم:

\$

a+b

Tensor(—)

```
with tf.Session() as sess:  
    print(sess.run(c))
```

```
tf.Tensor([34], shape=(1,), dtype=int32)
```

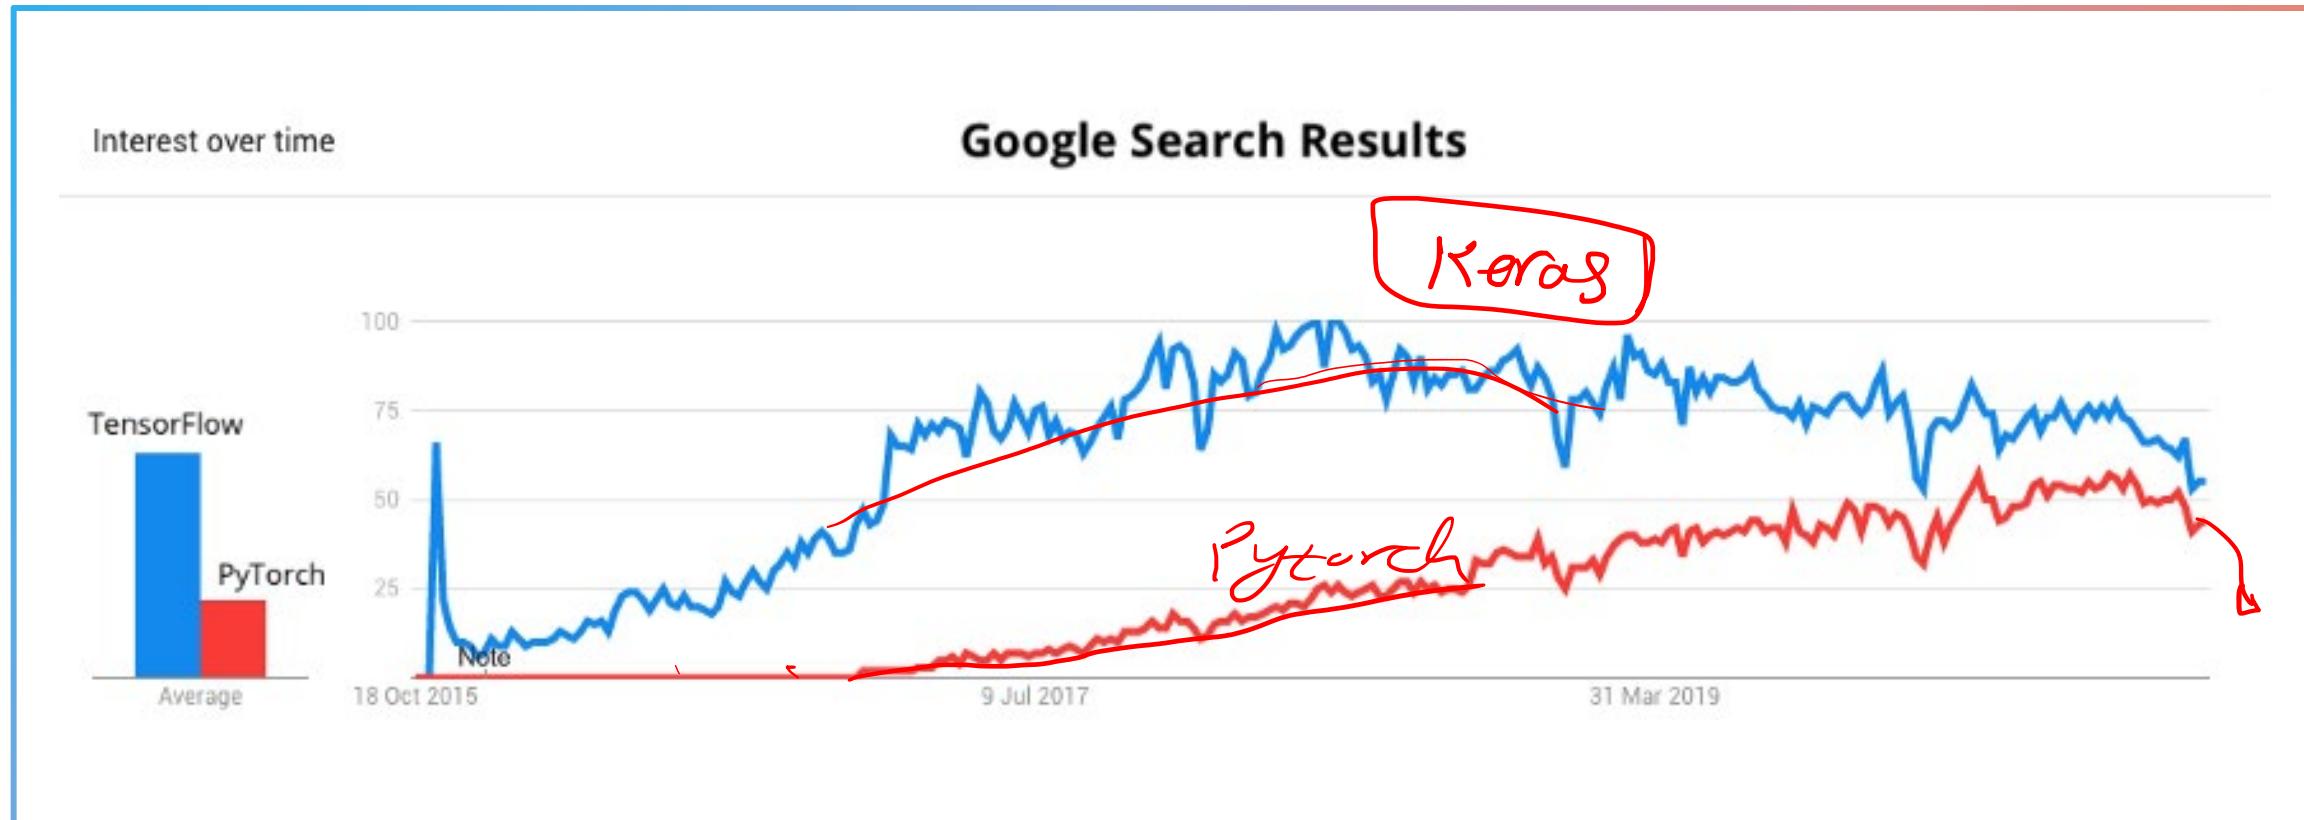
abf —

print("==")

می باید هر دو

tf.print

تنسورفلو احساس خطر کرد!



صفحه
graph

و از ۰.۲ Tensorflow را فعال کرد.

دیگه نمیخواهد گراف بسازی! هر عملیاتی انجام میشه همونجا محاسبه کن!

Python

```
one = tf.constant([12])
two = tf.constant([3])
three = tf.constant([2])
multres = tf.math.multiply(one, two)
subres = multres - three
```

```
tf.Tensor([34], shape=(1,), dtype=int32)
```

دو تا دستور دست گرمی :

```
print(tf.executing_eagerly())
```

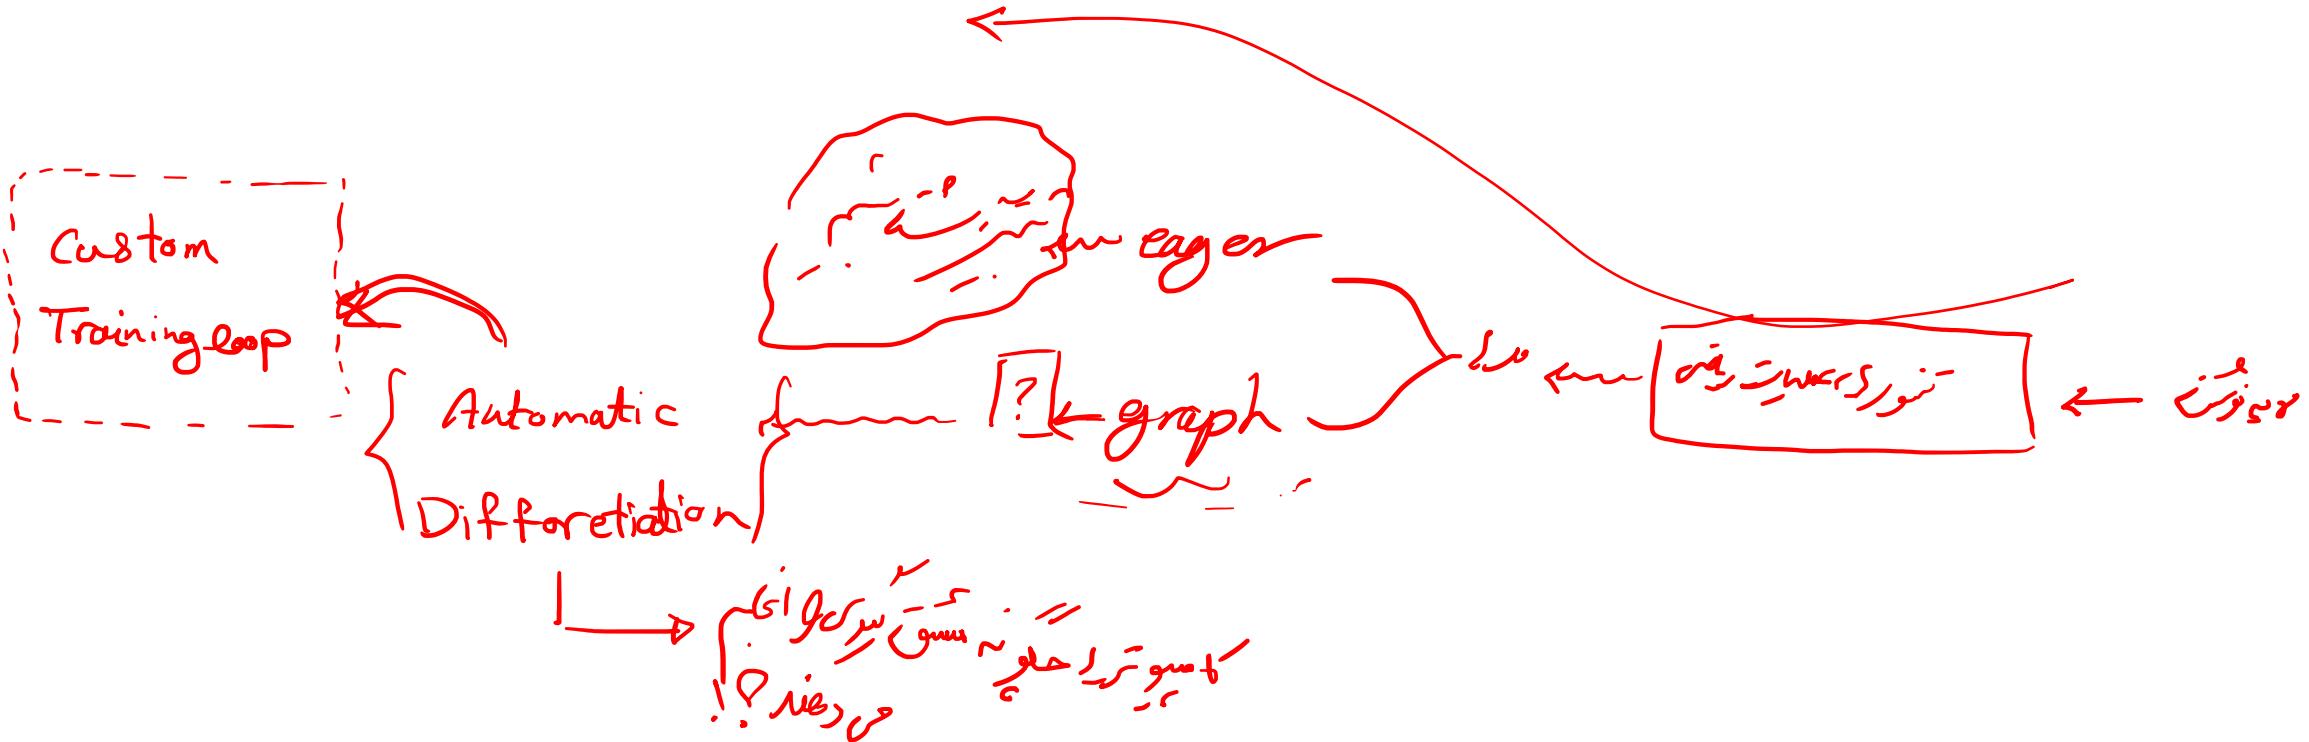
```
tf.compat.v1.disable_eager_execution()
```



چک کردن فعال بودن eager mode



غیر فعال کردن eager mode



کمی را بیشتر بشناسیم: Eager Mode



Evaluate Values immediately



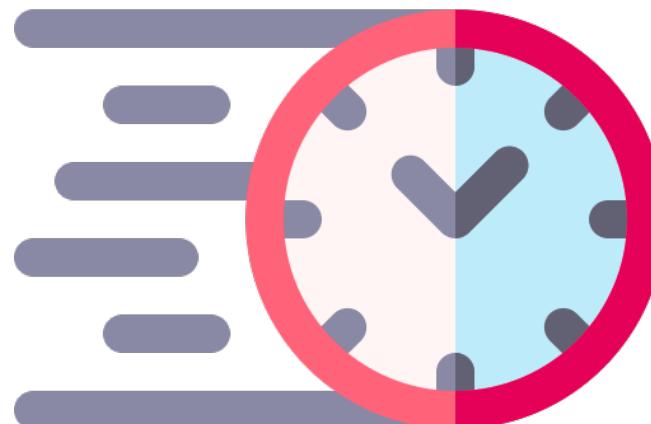
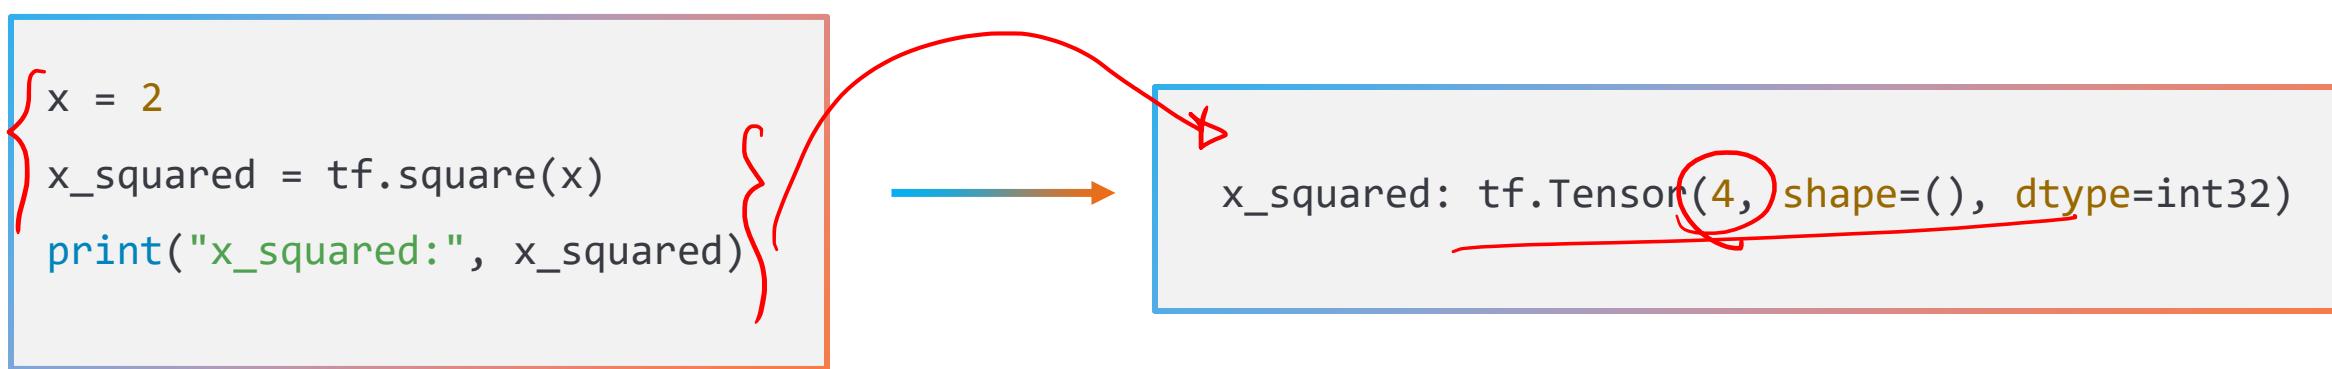
Broadcast Support



Operator Overloading

Numpy Compatibility

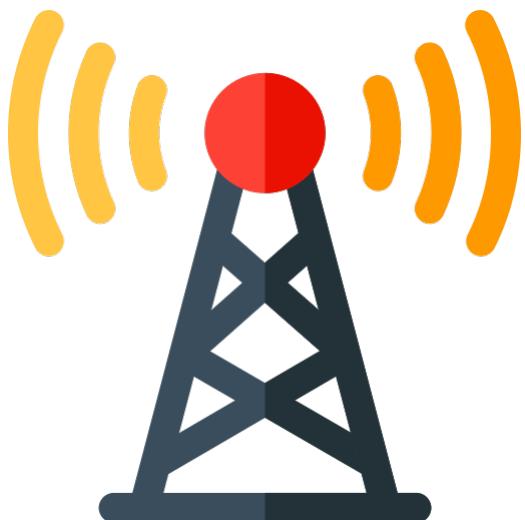
Evaluate Values immediately



Broadcast Support

```
a = tf.constant([[1, 2],  
                [3, 4]])  
  
b = tf.add(a, 1)  
  
print(b)
```

```
tf.Tensor(  
    [[2 3]  
     [4 5]], shape=(2, 2), dtype=int32)
```



Overload Operator

+

-

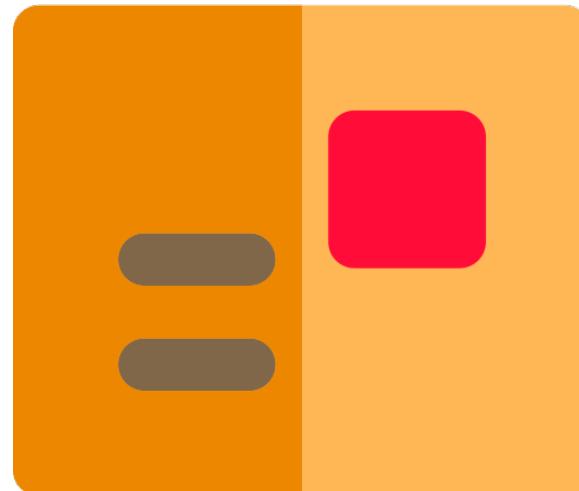
x

✓

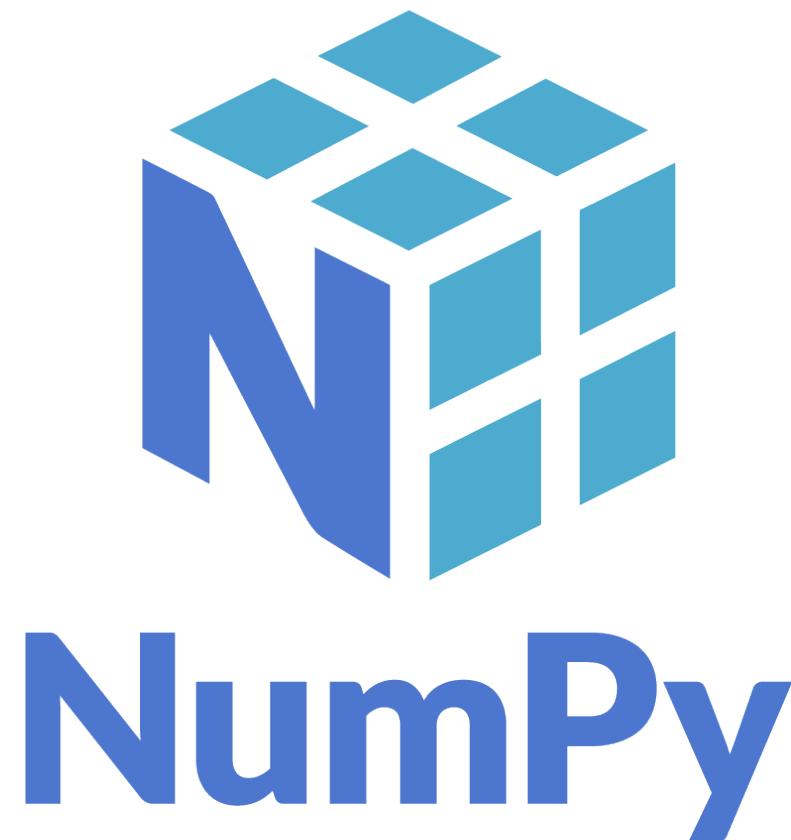
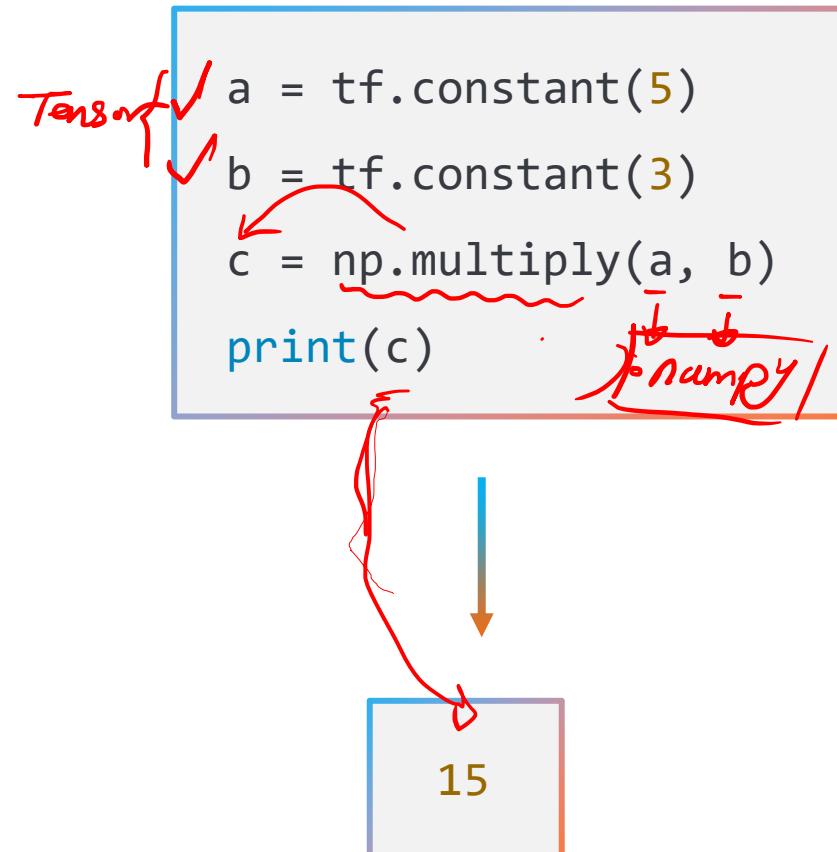
```
a = tf.constant([[1, 2],  
                 [3, 4]])  
  
b = a**2  
  
print(b)
```



```
tf.Tensor(  
[[1 4]  
[9 16]], shape=(2, 2), dtype=int32)
```



Numpy Compatibility

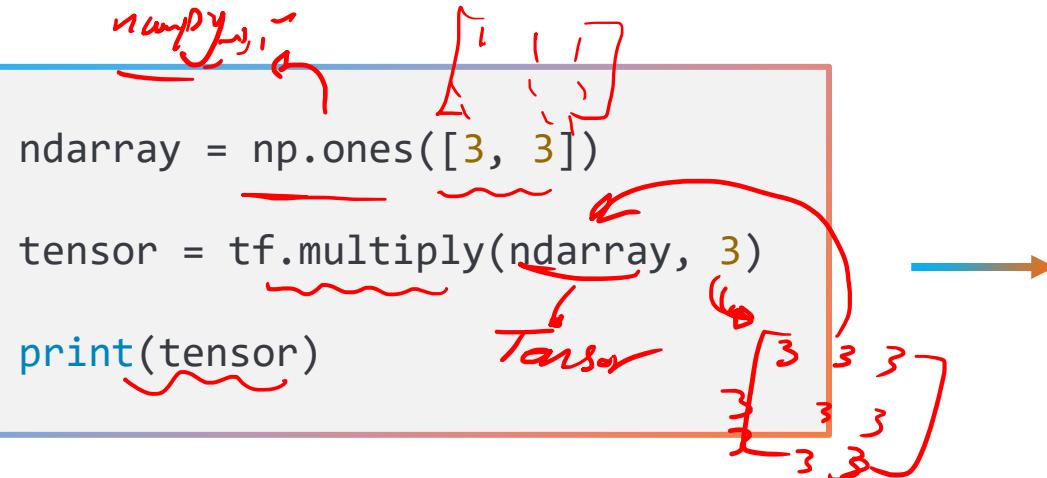


Numpy Interoperability

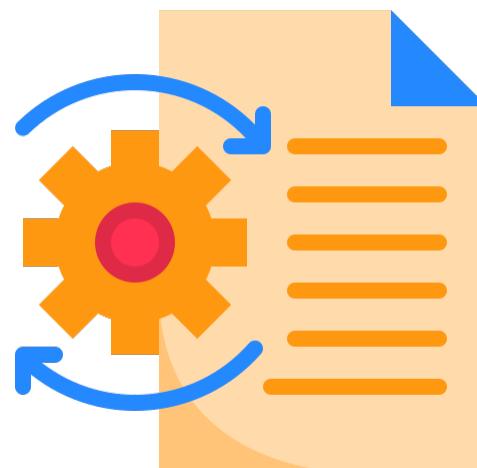
numpy, *i*

```
ndarray = np.ones([3, 3])
tensor = tf.multiply(ndarray, 3)
print(tensor)
```

Tensor



```
tf.Tensor(
    [[3. 3. 3.]
     [3. 3. 3.]
     [3. 3. 3.]], shape=(3, 3), dtype=float64)
```



Numpy به Tensor تبدیل

```
print(tensor.numpy())
```

```
[[3. 3. 3.]  
 [3. 3. 3.]  
 [3. 3. 3.]]
```



Evaluating Variable

```
{ v = tf.Variable(0.0)  
  print(v+1)  
  
{tf.Tensor(1.0, shape=(), dtype=float32)
```



Examine Custom Layers

```
class MyLayer(tf.keras.layers.Layer):  
  
    def __init__(self) -> None:  
        ✓ super().__init__()  
        ✓ self.my_var = tf.Variable(100) Tensor  
        self.my_other_var_list = [tf.Variable(x) for x in range(2)]  
            Tensor RP II Tensor  
  
    m = MyLayer()  
    out = [variable.numpy() for variable in m.variables]  
        1 1
```

[100, 0, 1]

چطور از مزایای Graph و Eager همزمان استفاده کنیم:

Eager → سر و خاطر

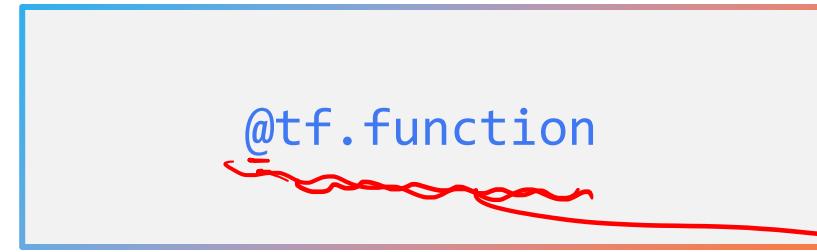
Graph → حکم

loss,
if else
while for
break continue

tf.cond

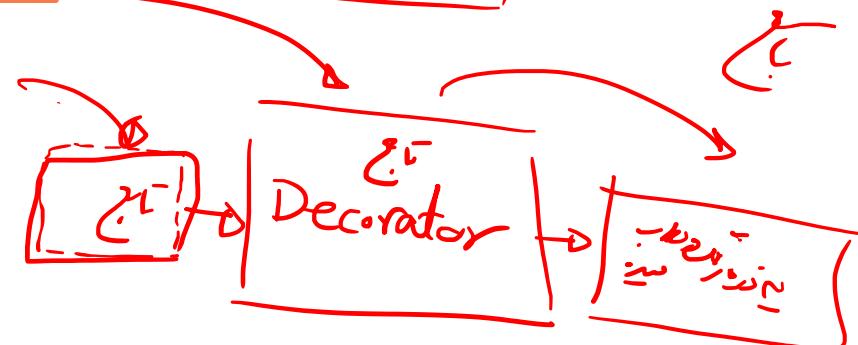
@tf.function

هر طبقه خواهد
ب سخورد بیشتر
Eager if else



@tf.function

Decorator



یک تابع عادی (eager مدرد)

```
{ def eager_function(x):
    result = x ** 2
    print(result)
    return result

x = tf.constant([1.0, 2.0, 3.0, 4.0])

eager_function(x)
}
```

```
tf.Tensor([1, 4, 9, 16], shape=(4,), dtype=float32)
```



تبديل همین تابع به Graph Mode

روش دوم

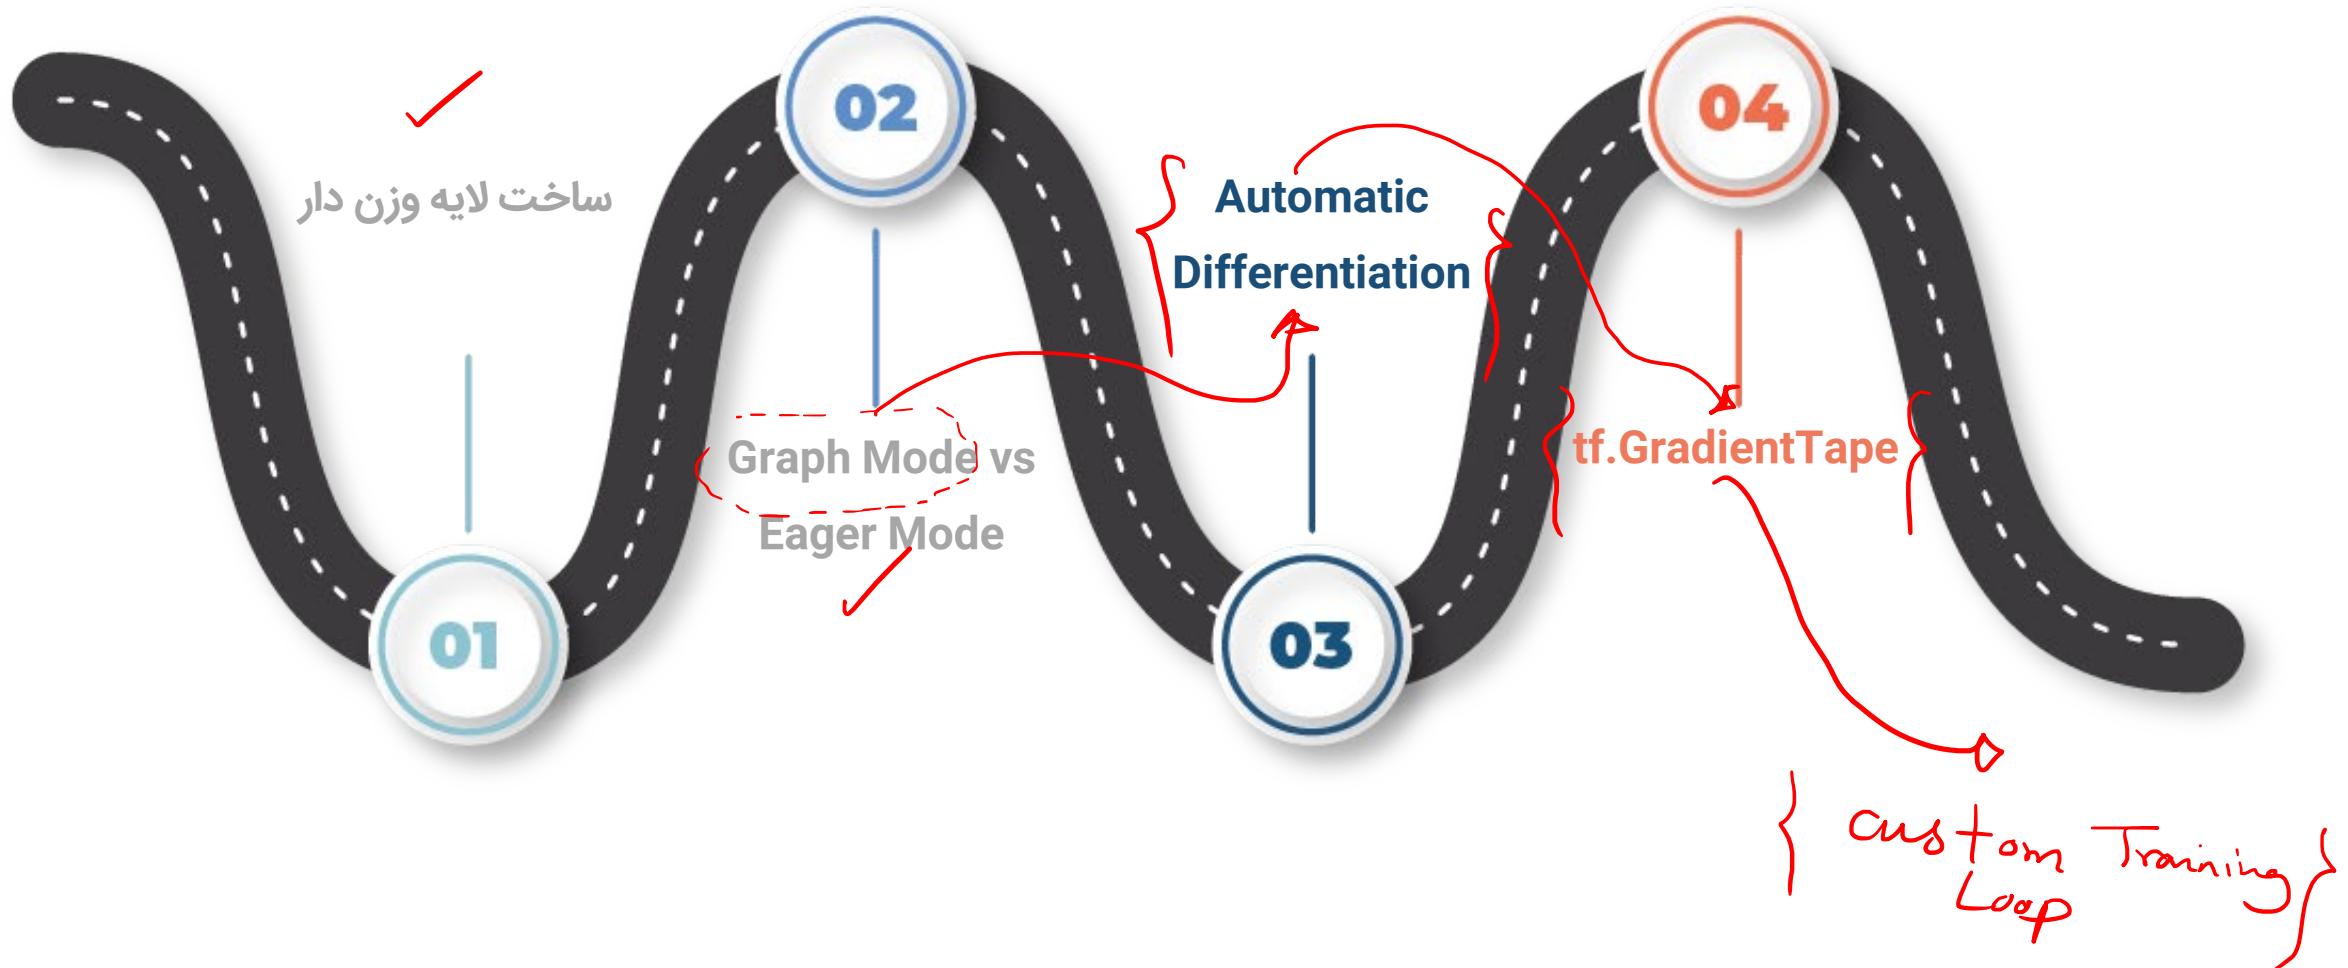
```
@tf.function  
def eager_function(x):  
    result = x ** 2  
    print(result)  
  
x = tf.constant([1.0, 2.0, 3.0, 4.0, 5.0])  
  
eager_function(x)
```

روش اول

```
def eager_function(x):  
    result = x ** 2  
    print(result)  
  
x = tf.constant([1.0, 2.0, 3.0, 4.0, 5.0])  
  
graph_function = tf.function(eager_function)  
graph_function(x)
```

Tensor("pow:0", shape=(4,), dtype=float32)

آنچه تاکنون گفته ایم.



کامپیوترها چگونه مشتق می‌گیرند؟



طوری که ما مشتق می‌گیریم:

$$y = e^{2x} - x^3$$

$$y = 2e^{2x} - 3x^2$$

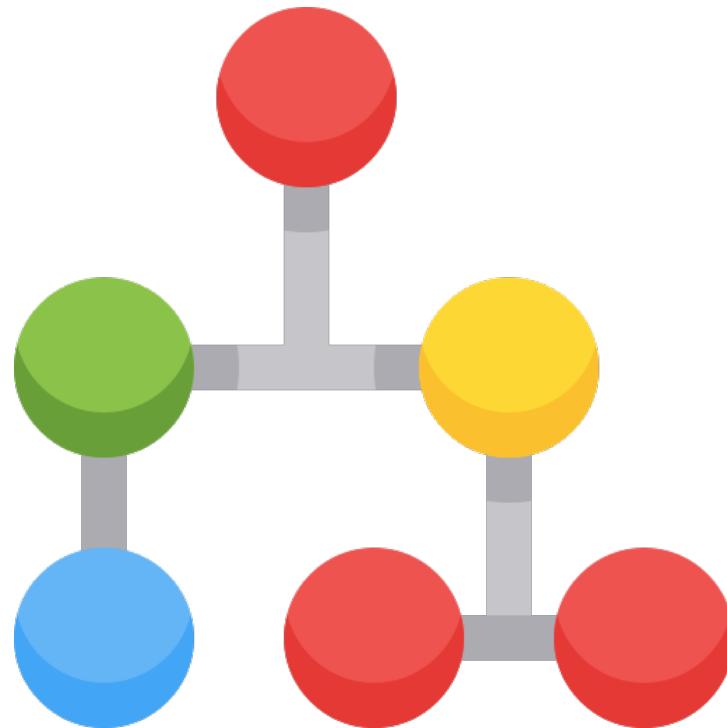
```
def f(x):  
    return np.exp(2*x) - x**3
```

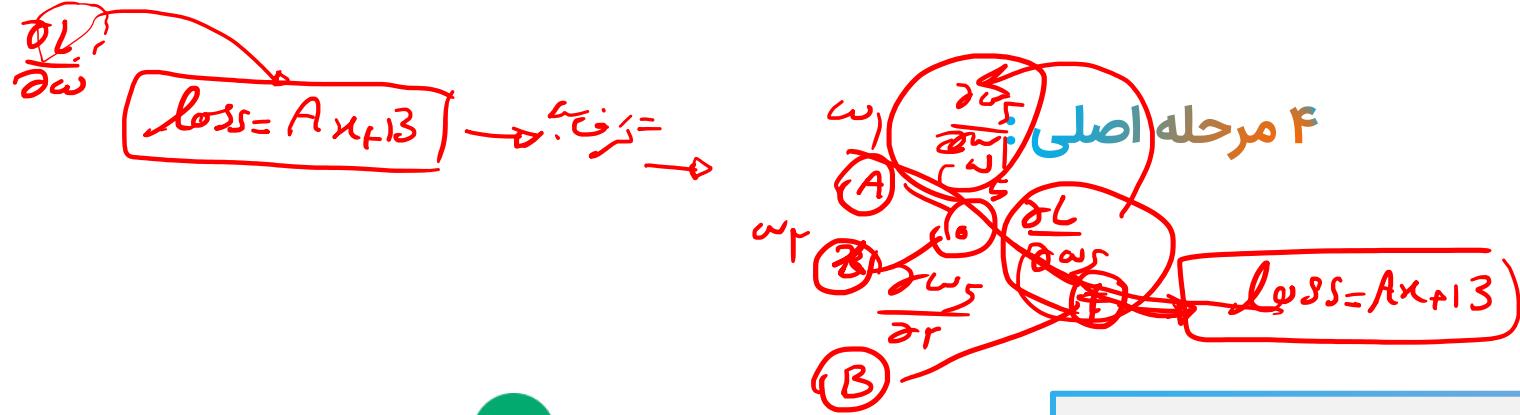
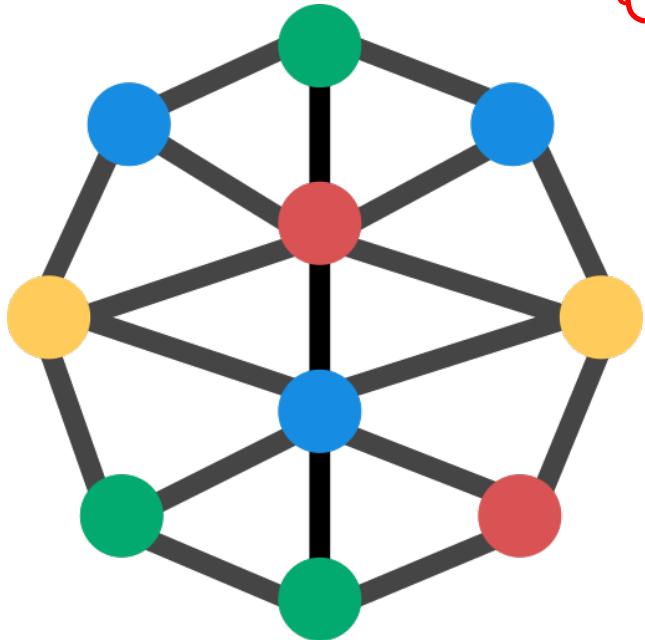
```
def f_prime(x):  
    return 2*np.exp(2*x) - 3*x**2
```

تلقیحیه

Automatic Differentiation

یکی از کاربردهای مهم Automatic Differentiation در Computational Graph است.



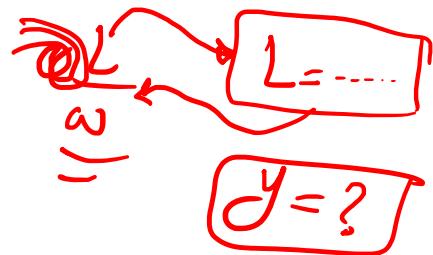


مرحله ۱: از رابطه خروجی گراف بساز

مرحله ۲: مشتق گیری های جزیی را برای هر node انجام بده.

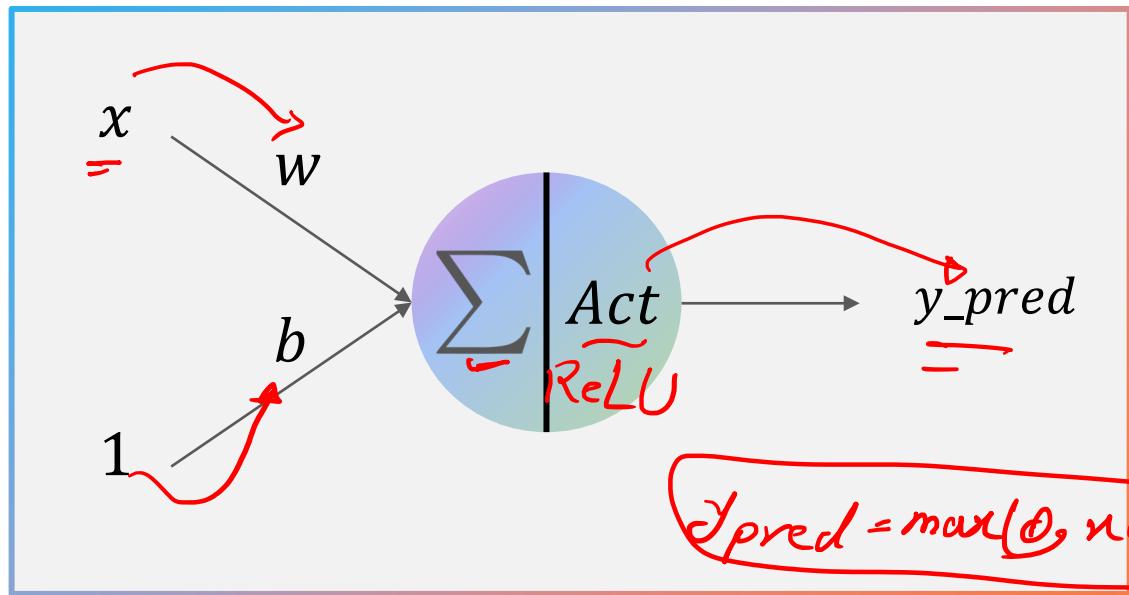
مرحله ۳: عملیات forward را بر روی گراف انجام بده.

مرحله ۴: به کمک Backpropagation مشتق های نهایی را محاسبه کن.



یک مساله ساده در نظر بگیرید:

$$\omega^+ = \omega^- = \frac{\partial L}{\partial \omega}$$

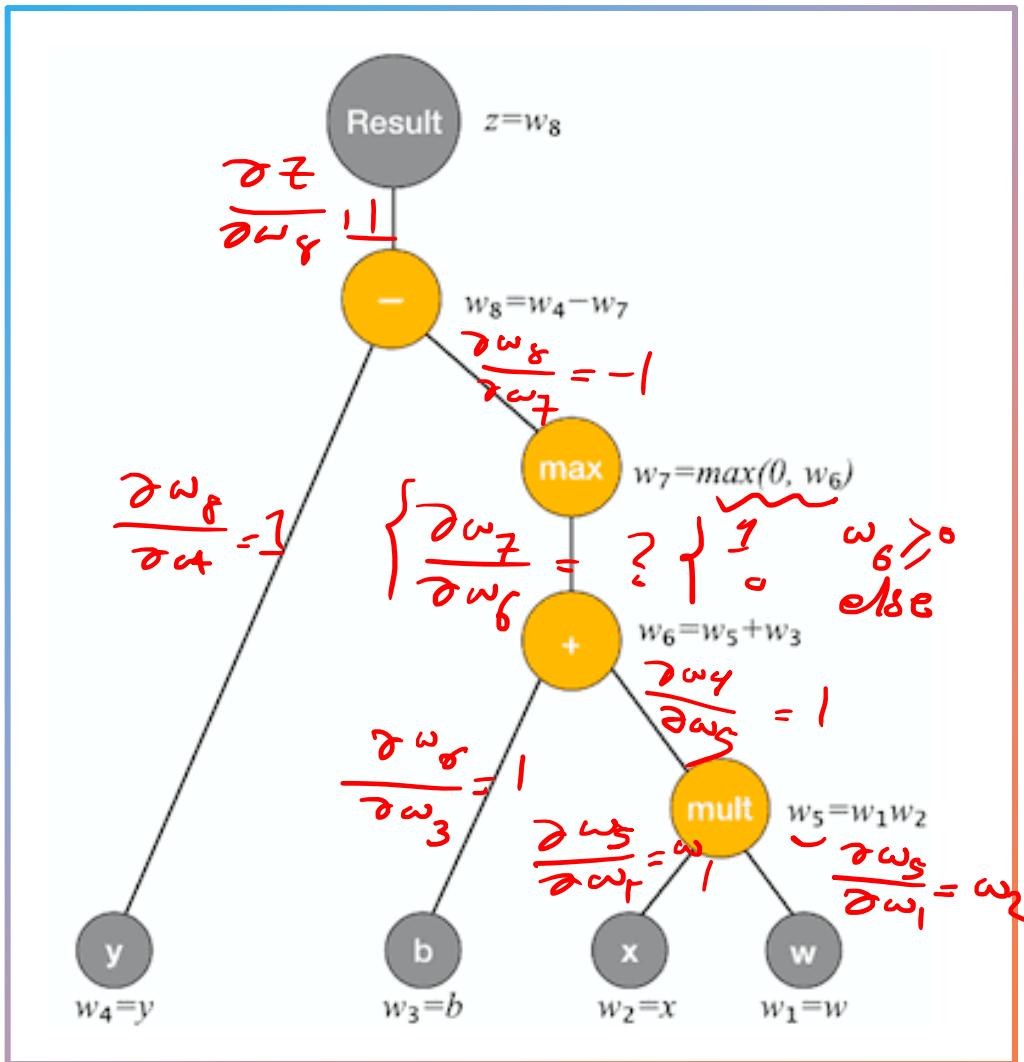


$$C(y, w, x, b) = y - \max(0, w \cdot x + b)$$

$$y_{pred} = \max(0, w \cdot x + b)$$

loss_

مرحله ۱: گراف ساخته می شود



Red annotations on the graph:

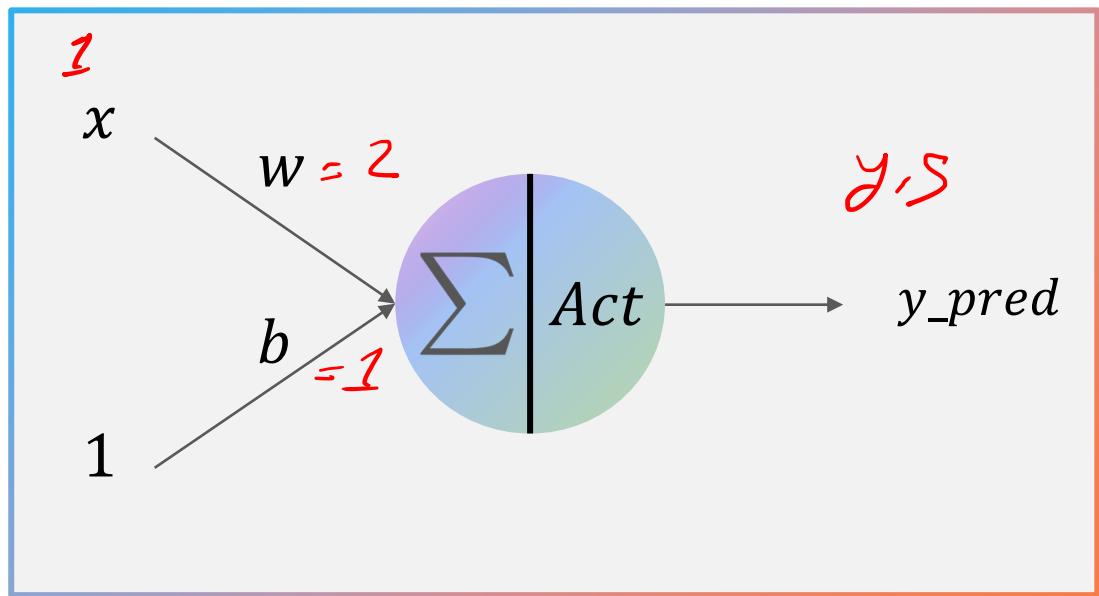
- $x_{\text{gate}} \rightarrow x$
- $y_{\text{gate}} \rightarrow y$

$$C(y, w, x, b) = y - \max(0, w \cdot x + b)$$

مرحله ۲: مشتقات جزئی محاسبه می گردد.

$\left\{ \begin{array}{l} \frac{\delta w_5}{\delta w_1} = \frac{\delta w_1 w_2}{\delta w_1} = w_2 \\ \frac{\delta w_6}{\delta w_5} = \frac{\delta w_5 + w_3}{\delta w_5} = 1 \\ \frac{\delta w_7}{\delta w_6} = \frac{\delta \max(0, w_6)}{\delta w_6} = \begin{cases} 0, & x < 0 \\ 1, & x > 0 \end{cases} \\ \frac{\delta w_8}{\delta w_4} = \frac{\delta w_4 - w_7}{\delta w_4} = 1 \end{array} \right.$	$\frac{\delta w_5}{\delta w_2} = \frac{\delta w_1 w_2}{\delta w_2} = w_1$
$\frac{\delta w_6}{\delta w_5} = \frac{\delta w_5 + w_3}{\delta w_5} = 1$	$\frac{\delta w_6}{\delta w_3} = \frac{\delta w_5 + w_3}{\delta w_3} = 1$
$\frac{\delta w_7}{\delta w_6} = \frac{\delta \max(0, w_6)}{\delta w_6} = \begin{cases} 0, & x < 0 \\ 1, & x > 0 \end{cases}$	$\frac{\delta w_8}{\delta w_7} = \frac{\delta w_4 - w_7}{\delta w_7} = -1$

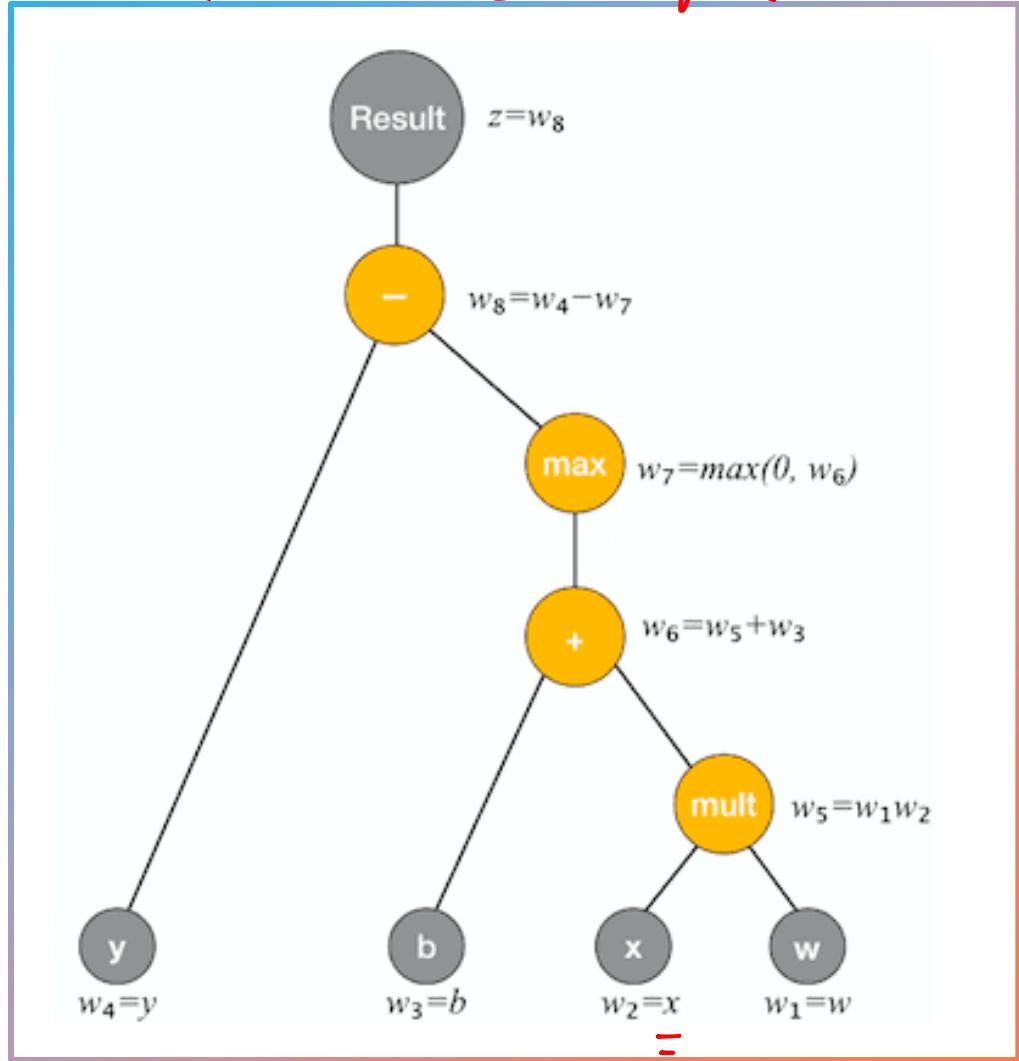
ورودی های فرضی:



$$y = 5, \quad w = 2, \quad x = 1, \quad b = 1$$

مرحله ۳: خروجی ها محاسبه می گردد.

Computational Graph



Node	Expression	Value
w_1	w	2
w_2	x	1
w_3	b	1
w_4	y	5
w_5	$w_1 \cdot w_2$	2
w_6	$w_5 + w_3$	3
w_7	$\max(0, w_6)$	3
w_8	$w_4 - w_7$	2
z	w_8	2

loss

مرحله F: با BP مشتق نهایی محاسبه می گردد.

$$\frac{\partial L}{\partial w_1} =$$

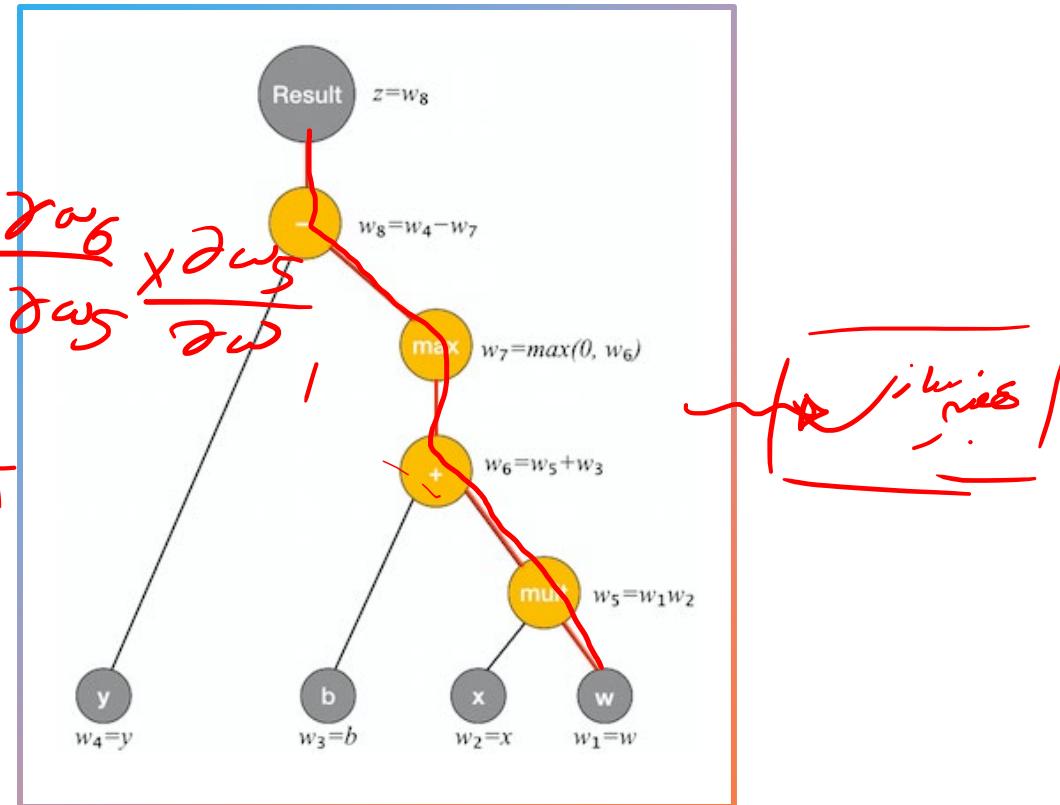
$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial w_8} \times \frac{\partial w_8}{\partial w_7} \times \frac{\partial w_7}{\partial w_6} \times \frac{\partial w_6}{\partial w_5} \times \frac{\partial w_5}{\partial w_1}$$

\downarrow

$\boxed{x \rightarrow 1} \times \left\{ \begin{array}{l} 0 \\ 1 \end{array} \right. \quad x + x \cdot w_2$

$$= -w_2 \left\{ \begin{array}{l} 0 \\ 1 \end{array} \right. \rightarrow$$

$$=$$

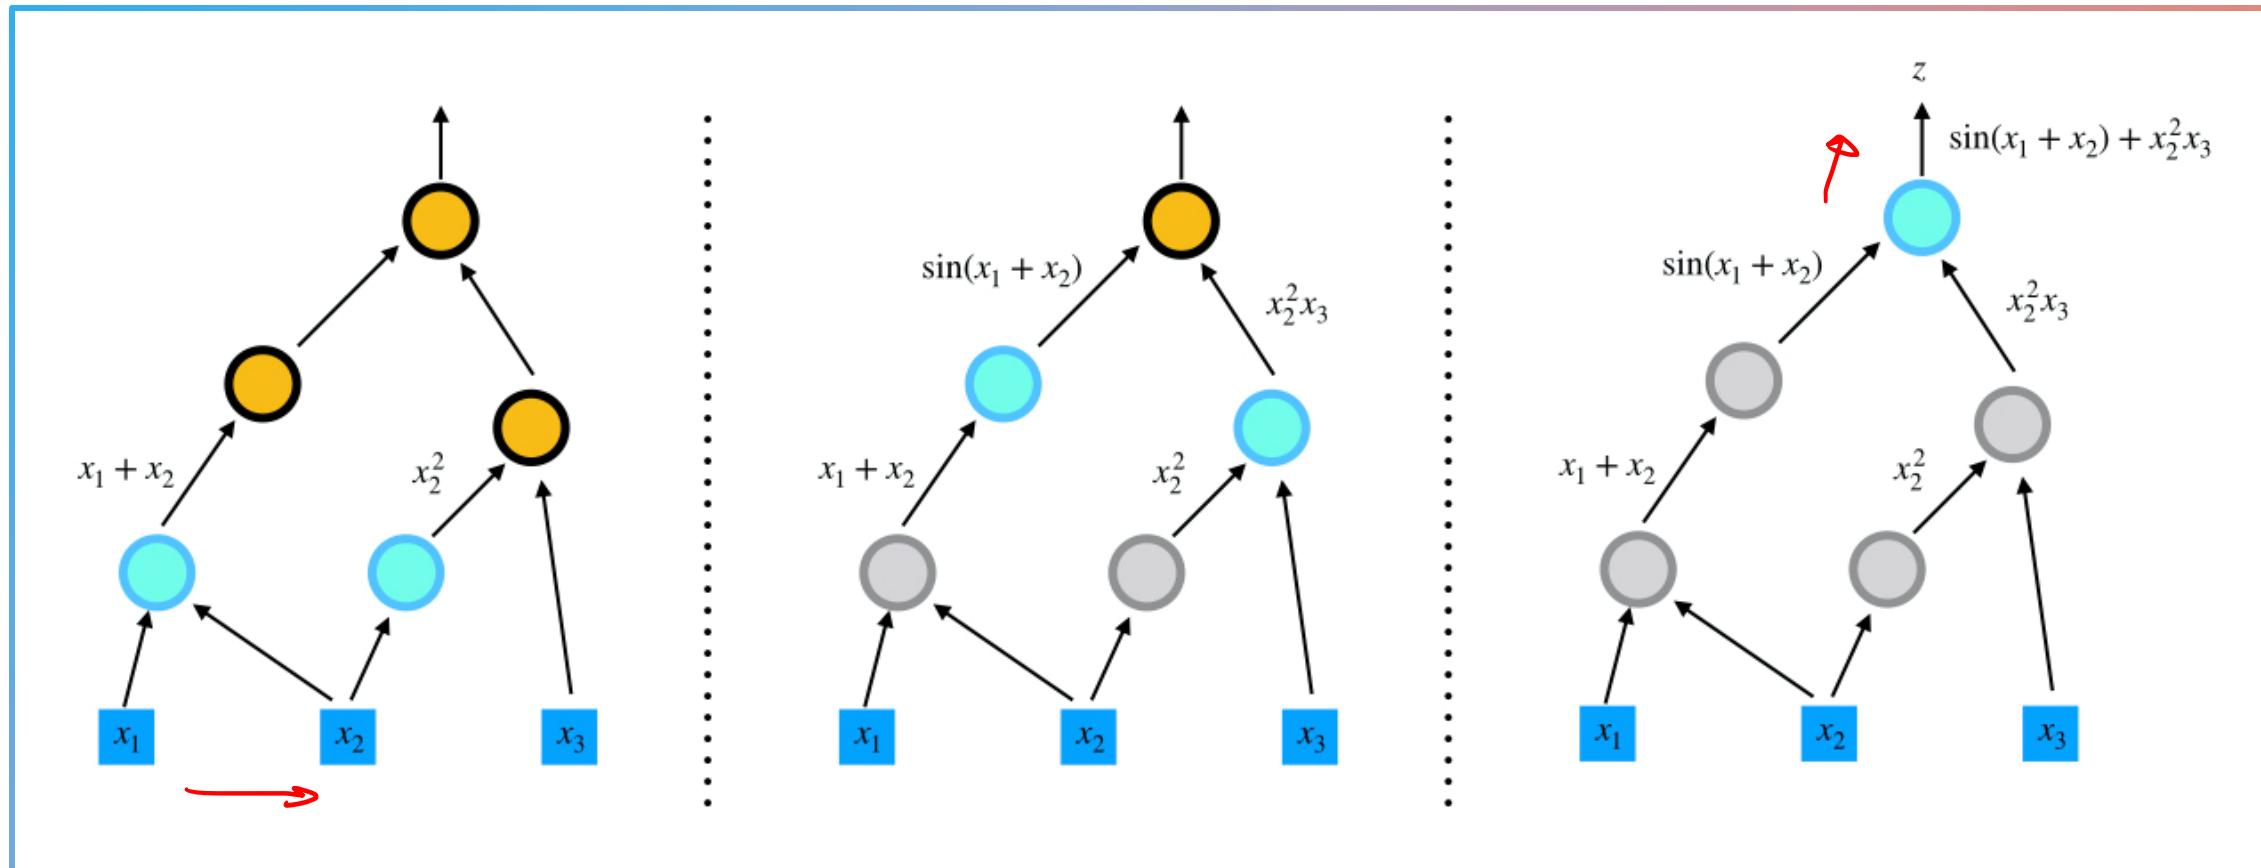


$$\frac{\delta z}{\delta w_1} = \frac{\delta z}{\delta w_8} \times \frac{\delta w_8}{\delta w_7} \times \frac{\delta w_7}{\delta w_6} \times \frac{\delta w_6}{\delta w_5} \times \frac{\delta w_5}{\delta w_1} = 1 \times (-1) \times \begin{cases} 0, & x < 0 \\ 1, & x > 0 \end{cases} \times 1 \times w_2 = \begin{cases} 0, & x < 0 \\ 1, & x > 0 \end{cases}$$

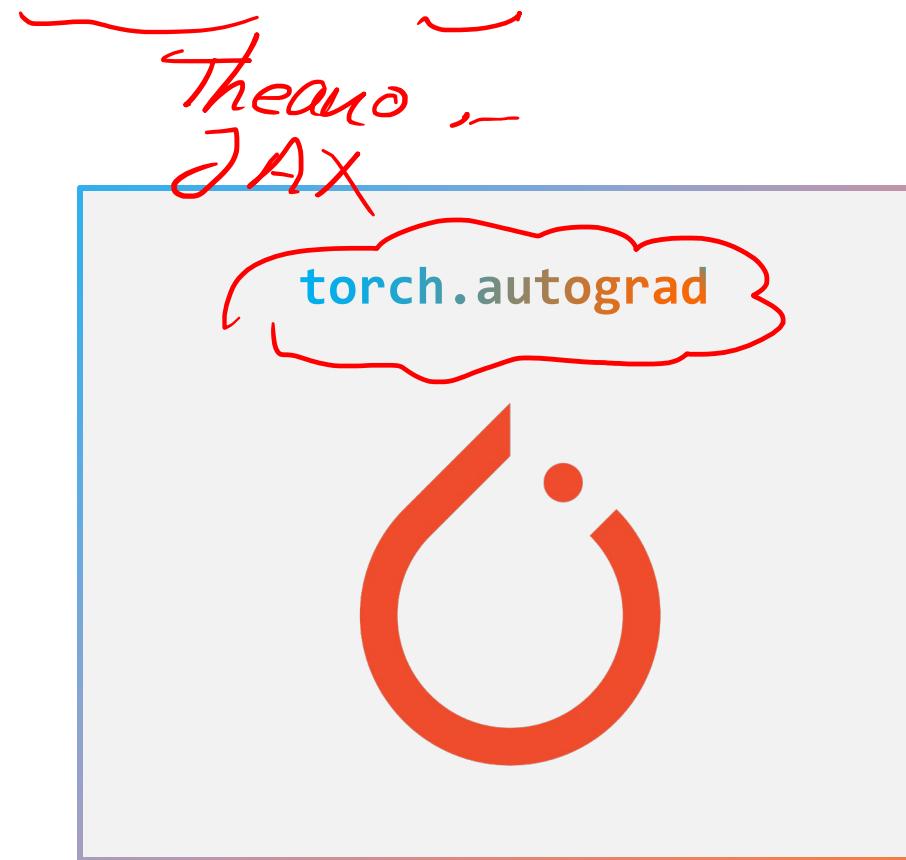
مثالی دیگر از ساخت یک گراف

خط: زیبایی

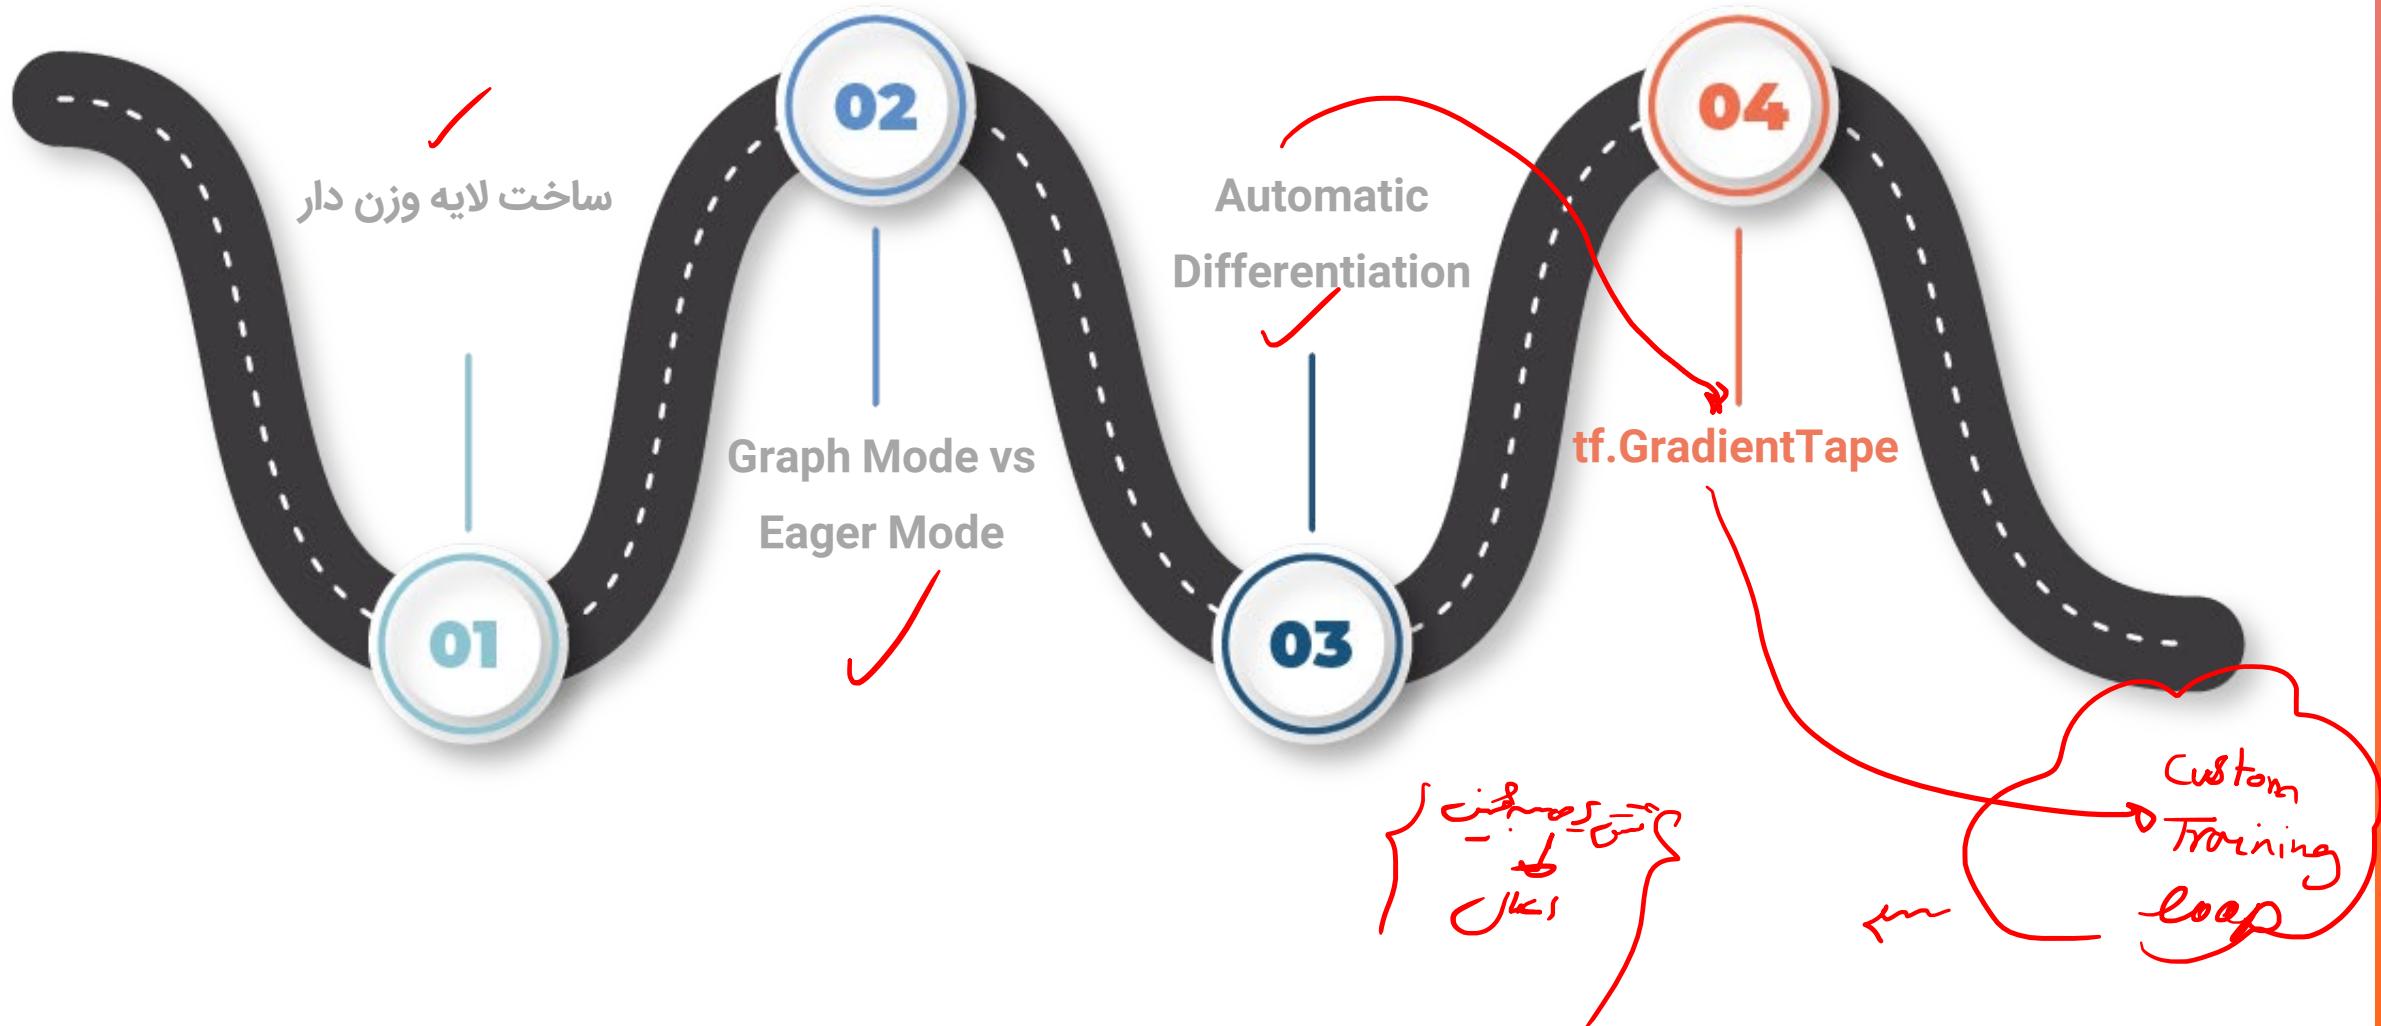
$$z = \sin(x_1 + x_2) + x_2^2 x_3$$



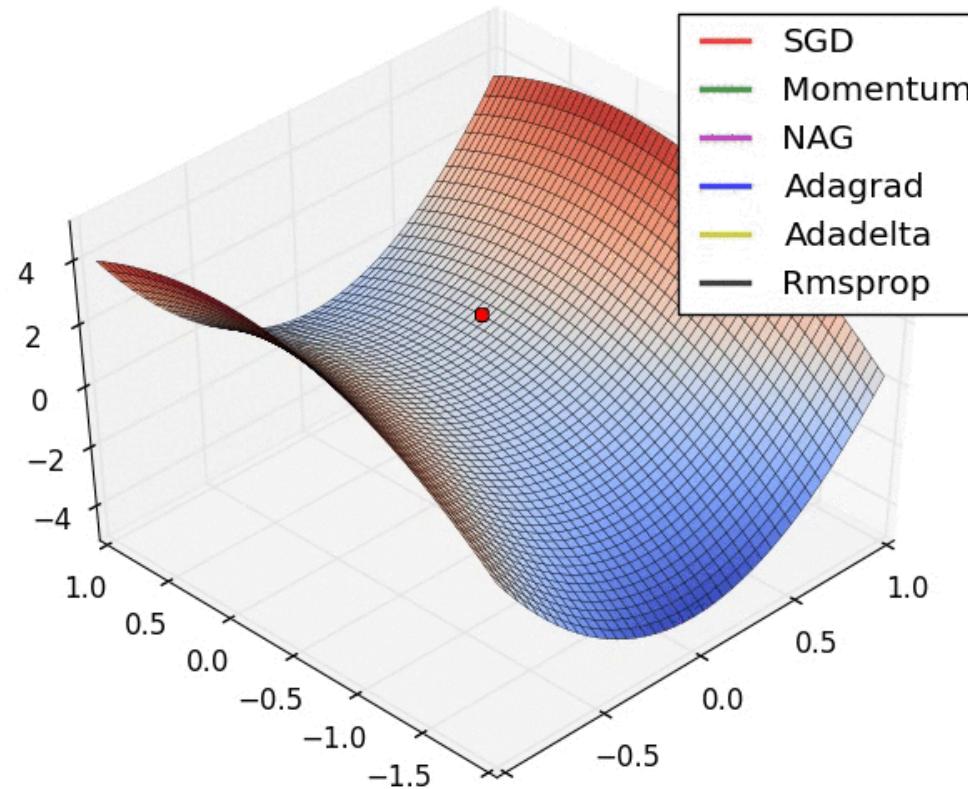
با این روش وزن ها را آپدیت می کنند.



آنچه تاکنون گفته ایم.



tf.GradientTape



مثال ۱: نحوه استفاده از tf.GradientTape

```
✓ x = tf.constant(5.0)
with tf.GradientTape() as tape:
    tape.watch(x)
    y = x**3
print(tape.gradient(y, x).numpy())
```

مقدار ثابت
متغیر
متغیر در زیر
متغیر در زیر

loss =
 $\frac{\partial y}{\partial x}$

به کمک **watch** ثابت ها و متغیرها شروع به track کردن می شوند.

به کمک **gradient** مشتق گیری نهایی انجام می گیرد.

$$\frac{\partial y}{\partial x} = 3x^2 = 3 \times 5^2 = 125$$

مثال ۲: استفاده از GradientTape برای Variable ها

```
x = tf.Variable(6.0, trainable=True)
with tf.GradientTape() as tape:
    y = x**3

print(tape.gradient(y, x).numpy())
```

متغیرهای trainable به صورت پیش فرض Track می شوند.

مثال ۳ : متوقف کردن ردیابی اتوماتیک متغیرها توسط GradientTape

```
x = tf.Variable(3.0, trainable=True)
with tf.GradientTape(watch_accessed_variables=False) as tape:
    y = x**3

print(tape.gradient(y, x))
```

خروجی این تکه کد None است.

مثال ۴: محاسبه مشتق های مرتبه بالاتر

$$\boxed{\frac{\partial^2 l}{\partial x^2}}$$

مُسْتَقِل
مُسْتَقِل

```
x = tf.Variable(3.0, trainable=True)
with tf.GradientTape() as tape1:
    with tf.GradientTape() as tape2:
        y = x ** 3
        order_1 = tape2.gradient(y, x)
        order_2 = tape1.gradient(order_1, x)

print(order_2.numpy()) # -> 18.0
```

برای این کار باید از `tf.GradientTape` به صورت تودر تو استفاده کنیم.

مثال ۵ : چندین بار استفاده از gradient

$\frac{\partial}{\partial} a$

```
a = tf.Variable(6.0, trainable=True)
b = tf.Variable(2.0, trainable=True)

with tf.GradientTape() as tape:
    y1 = a ** 2
    y2 = b ** 3

    print(tape.gradient(y1, a).numpy())
    print(tape.gradient(y2, b).numpy())
```

per

$$\begin{aligned} 2a &= 2 \times 6, [12] \\ &\rightarrow 3 \times 4, [12] \end{aligned}$$

RuntimeError: A non-persistent GradientTape can only be used to compute one set of gradients

نحوه حل: استفاده از persistent

```
a = tf.Variable(6.0, trainable=True)
b = tf.Variable(2.0, trainable=True)

with tf.GradientTape(persistent=True) as tape:
    y1 = a ** 2
    y2 = b ** 3

    {
        print(tape.gradient(y1, a).numpy())
        print(tape.gradient(y2, b).numpy())
    }
```

